

Lựa chọn mô hình và lựa chọn biến

Trần Việt Hà

Nguyễn Đình Mai Vi

Vũ Hà Thu

16/06/2026

Contents

1	Giới thiệu	3
2	Dữ liệu và thiết lập thực nghiệm	3
2.1	Quy trình thực hiện	3
2.2	EDA	3
2.3	Xây dựng mô hình hồi quy tuyến tính đầy đủ biến	6
3	Các tiêu chí lựa chọn biến cho mô hình	8
3.1	Hệ số xác định R^2	9
3.2	R^2 hiệu chỉnh (R_{adj}^2)	11
3.3	Mallows' C_p	13
3.4	AIC — Akaike Information Criterion	17
3.5	BIC — Bayesian Information Criterion	20
3.6	Khi nào dùng tiêu chuẩn nào?	24
3.7	Tổng hợp kết quả lựa chọn biến theo các tiêu chuẩn	24
4	Các phương pháp lựa chọn mô hình	26
4.1	Forward Selection (Lựa chọn tiến)	27
4.2	Backward Elimination (Loại trừ lùi)	33
4.3	Stepwise Selection (Lựa chọn từng bước)	40
4.4	So sánh tổng hợp các phương pháp lựa chọn biến	50
5	Lựa chọn mô hình và Bootstrap	51
5.1	Lựa chọn mô hình	51
5.2	Bootstrap	52

6	Kiểm chứng chéo (Cross - Validation)	54
6.1	Tập kiểm chứng độc lập (The Validation Set Approach)	54
6.2	Kiểm chứng chéo loại một (LOOCV)	56
6.3	Kiểm chứng chéo K phần	58
7	Tài liệu tham khảo	60

1 Giới thiệu

Trong hồi quy tuyến tính bội, số lượng biến giải thích được đưa vào mô hình có ảnh hưởng trực tiếp đến kết quả ước lượng và khả năng dự báo. Việc bổ sung thêm biến thường làm mô hình khớp với dữ liệu tốt hơn, thể hiện qua sự gia tăng của R^2 hoặc sự giảm của SSE. Tuy nhiên, một mô hình có quá nhiều biến có thể trở nên phức tạp, khó diễn giải và dễ xảy ra hiện tượng quá khớp (Overfitting).

Vì vậy, thay vì sử dụng toàn bộ các biến sẵn có, cần lựa chọn một tập biến phù hợp để xây dựng mô hình. Quá trình này thường dựa trên các tiêu chuẩn đánh giá như Adjusted R^2 , Mallows' C_p , AIC và BIC, kết hợp với các thủ tục lựa chọn biến như Forward Selection, Backward Elimination và Stepwise Selection.

Để minh họa các phương pháp trên, báo cáo sử dụng bộ dữ liệu `diabetes` trong R. Bộ dữ liệu gồm 442 quan sát với 10 biến giải thích và một biến target biểu thị mức độ tiến triển của bệnh tiểu đường. Trên bộ dữ liệu này, các phương pháp lựa chọn biến sẽ được áp dụng và so sánh nhằm tìm ra mô hình phù hợp cho bài toán dự báo.

2 Dữ liệu và thiết lập thực nghiệm

2.1 Quy trình thực hiện

Quy trình thực nghiệm được thực hiện theo các bước sau:

- EDA dữ liệu trên toàn bộ dataset.
- Chia data thành train và test (validation set), thực hiện xây dựng mô hình hồi quy tuyến tính và các phân tích trên tập train,
- Áp dụng các tiêu chuẩn lựa chọn biến gồm Adjusted R^2 , Mallows' C_p , AIC và BIC.
- Thực hiện các thủ tục lựa chọn biến gồm Forward Selection, Backward Elimination và Stepwise Selection.
- So sánh các mô hình thu được từ các phương pháp lựa chọn biến.
- Đánh giá khả năng dự báo trên tập test thông qua RMSE, MAE và test R^2 .
- Lựa chọn mô hình cuối cùng và đưa ra nhận xét.

2.2 EDA

```
data(diabetes)
df <- as.data.frame(cbind(diabetes$x, target = diabetes$y))
summary(df)
```

##	age	sex	bmi	map
##	Min. : -0.107226	Min. : -0.04464	Min. : -0.090275	Min. : -0.112400
##	1st Qu.: -0.037299	1st Qu.: -0.04464	1st Qu.: -0.034229	1st Qu.: -0.036656
##	Median : 0.005383	Median : -0.04464	Median : -0.007284	Median : -0.005671
##	Mean : 0.000000	Mean : 0.000000	Mean : 0.000000	Mean : 0.000000
##	3rd Qu.: 0.038076	3rd Qu.: 0.05068	3rd Qu.: 0.031248	3rd Qu.: 0.035644


```
## Max.      : 0.110727   Max.      : 0.05068   Max.      : 0.170555   Max.      : 0.132044
##          tc           ldl           hdl
## Min.      :-0.126781   Min.      :-0.115613   Min.      :-0.102307
## 1st Qu.   :-0.034248   1st Qu.   :-0.030358   1st Qu.   :-0.035117
## Median    :-0.004321   Median    :-0.003819   Median    :-0.006584
## Mean      : 0.000000   Mean      : 0.000000   Mean      : 0.000000
## 3rd Qu.   : 0.028358   3rd Qu.   : 0.029844   3rd Qu.   : 0.029312
## Max.      : 0.153914   Max.      : 0.198788   Max.      : 0.181179
##          tch           ltg           glu           target
## Min.      :-0.076395   Min.      :-0.126097   Min.      :-0.137767   Min.      : 25.0
## 1st Qu.   :-0.039493   1st Qu.   :-0.033249   1st Qu.   :-0.033179   1st Qu.   : 87.0
## Median    :-0.002592   Median    :-0.001948   Median    :-0.001078   Median    :140.5
## Mean      : 0.000000   Mean      : 0.000000   Mean      : 0.000000   Mean      :152.1
## 3rd Qu.   : 0.034309   3rd Qu.   : 0.032433   3rd Qu.   : 0.027917   3rd Qu.   :211.5
## Max.      : 0.185234   Max.      : 0.133599   Max.      : 0.135612   Max.      :346.0
```

Bộ dữ liệu gồm 10 biến giải thích và 1 biến phụ thuộc target. Các biến giải thích đã được chuẩn hóa nên có giá trị trung bình xấp xỉ 0. Biến target dao động từ 25 đến 346, với trung bình khoảng 152.1, cho thấy mức độ tiến triển bệnh tiểu đường có sự khác biệt đáng kể giữa các bệnh nhân.

Trước khi lựa chọn biến, báo cáo tiến hành khám phá dữ liệu để quan sát mối quan hệ giữa biến phụ thuộc target và các biến giải thích

```
df %>%
  pivot_longer(cols = -target, names_to = "variable", values_to = "value") %>%
  ggplot(aes(x = value, y = target)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "lm", se = FALSE) +
  facet_wrap(~ variable, scales = "free_x") +
  labs(
    title = "Quan hệ giữa các biến của mô hình và target",
    x = "Biến",
    y = "target"
  )
```

Quan hệ giữa các biến của mô hình và target




Từ các biểu đồ phân tán ở trên có thể thấy các biến bmi, ltg, map và glu có xu hướng tăng cùng với target, trong khi hdl có xu hướng giảm khi target tăng. Trong số đó, mối quan hệ của bmi và ltg với target thể hiện khá rõ qua dạng phân bố của các điểm dữ liệu.

Các biến age, ldl, tc và tch cũng cho thấy xu hướng đồng biến với target, tuy nhiên mức độ không rõ bằng các biến trên. Riêng biến sex gần như không thể hiện mối quan hệ tuyến tính đáng kể với target khi xét riêng lẻ.

Nhìn chung, các scatter plots giúp nhận diện sơ bộ những biến có khả năng ảnh hưởng đến target trước khi tiến hành xây dựng và lựa chọn mô hình hồi quy.

```
cor_matrix <- cor(df)

corrplot(
  cor_matrix,
  method = "color",
  type = "upper",
  tl.cex = 0.8,
  addCoef.col = "black",
  number.cex = 0.6
)
```



Ma trận tương quan cho thấy biến target có tương quan dương tương đối rõ với các biến bmi, map, tc, ldl, tch, ltg, glu. Trong đó, ltg và bmi là hai biến có tương quan cao nhất với target. Ngược lại, hdl có tương quan âm với target, còn sex gần như không có tương quan tuyến tính đơn biến với target.

Một số cặp biến độc lập có tương quan cao, đặc biệt là tc-ldl, hdl-tch, ldl-tch, tch-ltg cho thấy có thể tồn tại hiện tượng đa cộng tuyến. Do đó, việc lựa chọn biến là cần thiết để xây dựng mô hình gọn hơn, tránh sử dụng nhiều biến mang thông tin trùng lặp.

2.3 Xây dựng mô hình hồi quy tuyến tính đầy đủ biến

Để đánh giá các phương pháp lựa chọn biến và lựa chọn mô hình, bộ dữ liệu được chia thành hai phần: tập huấn luyện (train) và tập kiểm tra (test) theo tỷ lệ 80:20. Tập train được sử dụng để xây dựng mô hình và thực hiện lựa chọn biến, trong khi tập test được dùng để đánh giá khả năng dự báo của các mô hình sau khi lựa chọn.

```
set.seed(347)

# Chia train:test theo tỉ lệ 80:20
train_index <- sample(1:nrow(df), size = 0.8 * nrow(df))

train_data <- df[train_index, ]
test_data <- df[-train_index, ]
```

```
dim(train_data)
```

```
## [1] 353 11
```

```
dim(test_data)
```

```
## [1] 89 11
```

```
full_model <- lm(target ~ ., data = train_data)
```

```
summary(full_model)
```

```
##
## Call:
## lm(formula = target ~ ., data = train_data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -153.361  -37.612   -1.205    37.236   148.804
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   153.437     2.923   52.495 < 2e-16 ***
## age           12.981     68.640    0.189 0.850109
## sex          -255.072     68.749   -3.710 0.000242 ***
## bmi           478.669     75.547    6.336 7.43e-10 ***
## map           355.903     73.341    4.853 1.85e-06 ***
## tc           -749.672    495.989   -1.511 0.131592
## ldl           497.297    398.898    1.247 0.213369
## hdl            55.853    250.479    0.223 0.823680
## tch            52.106    188.380    0.277 0.782254
## ltg           766.194    196.771    3.894 0.000119 ***
## glu           109.987     73.685    1.493 0.136449
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 54.82 on 342 degrees of freedom
## Multiple R-squared:  0.5075, Adjusted R-squared:  0.4931
## F-statistic: 35.24 on 10 and 342 DF,  p-value: < 2.2e-16
```

Mô hình hồi quy đầy đủ có ý nghĩa thống kê tổng thể với p-value của kiểm định F nhỏ hơn $2.2e-16$. Giá trị $R^2 = 0.5075$ cho thấy mô hình giải thích được khoảng 50.75% biến thiên của target, trong khi $R^2_{adj} = 0.4931$ cho thấy sau khi điều chỉnh theo số lượng biến, tỷ lệ giải thích còn khoảng 49.31%.

Xét từng biến giải thích, sex, bmi, map và ltg có ý nghĩa thống kê ở mức 5%. Trong đó, bmi, map và ltg có ảnh hưởng cùng chiều đến target, còn sex có ảnh hưởng ngược chiều. Các biến còn lại có p-value lớn

hơn 0.05 nên chưa có đủ bằng chứng để khẳng định ảnh hưởng riêng lẻ của chúng trong mô hình khi đã xét đồng thời các biến khác.

Mặc dù mô hình đầy đủ sử dụng toàn bộ 10 biến giải thích, chỉ một số biến thực sự có ý nghĩa thống kê. Điều này cho thấy mô hình có thể chứa những biến không cần thiết. Vì vậy, các phương pháp lựa chọn biến sẽ được áp dụng ở các phần tiếp theo nhằm tìm ra mô hình gọn hơn nhưng vẫn đảm bảo khả năng giải thích và dự báo.

3 Các tiêu chí lựa chọn biến cho mô hình

Khi xây dựng mô hình hồi quy, mục tiêu không chỉ là tìm mô hình có độ khớp (*goodness-of-fit*) cao mà còn cần đảm bảo mô hình đủ đơn giản để dễ diễn giải và sử dụng. Trong nhiều trường hợp, có thể chấp nhận giảm một phần nhỏ độ khớp để đổi lấy một mô hình gọn hơn với số lượng biến ít hơn.

Nếu chỉ dựa vào tổng bình phương sai số

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

trong đó n là cỡ mẫu (số quan sát), y_i là giá trị thực tế và $\hat{y}_i$ là giá trị dự báo của quan sát thứ i , thì việc bổ sung thêm biến giải thích sẽ không làm SSE tăng. Tương tự, hệ số xác định R^2 cũng không giảm khi thêm biến vào mô hình. Do đó, khi sử dụng riêng SSE hoặc R^2 để đánh giá, các mô hình có nhiều biến thường sẽ được ưu tiên hơn.

Tuy nhiên, mô hình có quá nhiều biến có thể dẫn đến hiện tượng *overfitting*, tức là mô hình khớp rất tốt với dữ liệu huấn luyện (train) nhưng lại dự báo kém trên dữ liệu mới (test hoặc out-of-time). Vì vậy, cần có các tiêu chuẩn lựa chọn biến nhằm cân bằng giữa độ khớp và độ phức tạp của mô hình.


3.0.1 Ký hiệu và quy ước

Để thống nhất ký hiệu trong toàn bộ phần này:

- n : **cỡ mẫu** — tổng số quan sát trong tập dữ liệu.
- p : **số biến giải thích** (predictors) có trong mô hình con đang xét.
- $k = p + 1$: **số tham số cần ước lượng** của mô hình hồi quy tuyến tính Y theo $X_1, \dots, X_p$, gồm p hệ số góc $\beta_1, \dots, \beta_p$ và hệ số chặn β_0 .
- $y_i, \hat{y}_i$: giá trị thực tế và giá trị dự báo của quan sát thứ i .
- $\hat{\sigma}^2$: ước lượng không chệch của phương sai sai số σ^2 , lấy từ mô hình đầy đủ.

Lưu ý quan trọng về ký hiệu: Hệ số phạt trong C_p , AIC, BIC nhân với **số tham số** $k = p + 1$, không phải số biến p . Nhiều tài liệu (Sheather 2009, Weisberg 2014) dùng ký hiệu p nhưng định nghĩa là “số tham số kể cả intercept” — tức đúng bằng k theo quy ước này. ISL (James et al. 2023) dùng ký hiệu d cho cùng đại lượng đó.

Đánh đổi Bias-Variance trên dữ liệu Diabetes



Bài toán lựa chọn biến thực chất là tìm sự cân bằng giữa độ khớp (*goodness-of-fit*) và độ phức tạp của mô hình. Một mô hình có nhiều biến thường khớp dữ liệu tốt hơn, nhưng cũng dễ trở nên phức tạp và có nguy cơ quá khớp. Ngược lại, mô hình quá đơn giản có thể bỏ sót những thông tin quan trọng.

Các tiêu chuẩn như Adjusted R^2 , Mallows' C_p , AIC và BIC đều được xây dựng theo cùng một ý tưởng: kết hợp giữa mức độ sai khác của mô hình với dữ liệu (*lack-of-fit*) và một thành phần phạt (*penalty*) đối với số lượng biến được sử dụng,

$$\text{Tiêu chuẩn} = \text{Lack-of-fit} (\downarrow) + \text{Penalty} (\uparrow)$$

Điểm khác biệt giữa các tiêu chuẩn nằm ở cách xây dựng thành phần penalty. Chẳng hạn, Mallows' C_p xuất phát từ việc ước lượng sai số dự báo ngoài mẫu, AIC dựa trên lý thuyết hợp lý cực đại và khoảng cách Kullback–Leibler, còn BIC được xây dựng từ quan điểm Bayes. Trong phần này, ta sử dụng phương pháp lựa chọn biến best subset selection để minh họa cách các tiêu chuẩn này hoạt động trong thực tế, từ đó rút ra nguyên lý lựa chọn biến tối ưu dựa trên từng tiêu chí.

3.1 Hệ số xác định R^2

3.1.1 Công thức

Đối với hồi quy tuyến tính, hệ số xác định R^2 được định nghĩa là:

$$\boxed{R^2 = 1 - \frac{SSE}{SST}}, \quad SST = \sum_{i=1}^n (y_i - \bar{y})^2. \quad (2)$$

Trong đó:

- SST là tổng biến thiên của Y quanh trung bình $\bar{y}$,
- SSE là phần biến thiên *chưa* được mô hình giải thích.
- Do đó $R^2 \in [0, 1]$ đo **tỷ lệ phương sai của Y** được mô hình giải thích.

3.1.2 Lý giải nhược điểm luôn tăng khi thêm biến dẫn đến R^2 không thể dùng để chọn biến

Hệ số xác định R^2 phản ánh mức độ biến thiên của Y được mô hình giải thích. Tuy nhiên, khi mở rộng mô hình bằng cách thêm các biến độc lập mới, thuật toán OLS sẽ có thêm không gian để tối ưu hóa và làm giảm tổng bình phương sai số (SSE). Ngay cả khi biến mới được thêm vào không có ý nghĩa thống kê, thuật toán vẫn có thể vô tình nắm bắt các nhiễu ngẫu nhiên (noise) của tập dữ liệu hiện tại. Hệ quả là R^2 luôn có xu hướng tăng đơn điệu theo số lượng tham số, làm tăng rủi ro quá khớp (overfitting) nếu không có cơ chế kiểm soát.

- **Lack-of-fit:** Từ số SSE (càng lớn mô hình càng kém khớp).
- **Penalty: Không có (0).** Sự thiếu vắng của hình phạt khiến R^2 luôn chọn mô hình lớn.

3.1.2.1 Chứng minh toán học: Tại sao R^2 luôn tăng khi thêm biến?

• Bước 1: Sự cố định của mẫu số (SST)

- Đại lượng $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ đo lường toàn bộ sự biến động của biến mục tiêu Y xung quanh giá trị trung bình mẫu
- Giá trị này được tính toán hoàn toàn từ dữ liệu thực tế của Y , do đó nó là một **hằng số bất biến**, hoàn toàn độc lập và không thay đổi cho dù ta đưa bao nhiêu biến độc lập X vào mô hình.

• Bước 2: Bản chất hình học của việc tối ưu hóa SSE trong OLS

- Thuật toán Bình phương Tối thiểu (OLS) tìm kiếm tập hợp hệ số $\hat{\beta}$ bằng cách giải bài toán cực tiểu hóa hình học: $\min_{\beta} \|Y - X\beta\|^2$.
- Giả sử ta đang có một mô hình con $\mathcal{M}_1$ với p biến, không gian cột của ma trận thiết kế là $\mathcal{X}_1 \subset \mathbb{R}^n$. Giá trị hình chiếu của Y lên không gian này cho ta tổng sai số bình phương SSE_1 .
- Khi ta thêm một biến mới X_{new} để tạo ra mô hình $\mathcal{M}_2$, không gian cột mở rộng thành $\mathcal{X}_2 = \mathcal{X}_1 \oplus \text{span}(X_{new})$. Lúc này, $\mathcal{X}_1$ trở thành một tập con không gian của $\mathcal{X}_2$ ($\mathcal{X}_1 \subseteq \mathcal{X}_2$).

• Bước 3: Hệ quả toán học của việc mở rộng không gian nghiệm

- Vì không gian tìm kiếm nghiệm tối ưu của mô hình $\mathcal{M}_2$ bao hàm toàn bộ không gian của mô hình $\mathcal{M}_1$, thuật toán OLS ở mô hình $\mathcal{M}_2$ luôn có một phương án dự phòng là gán hệ số $\hat{\beta}_{new} = 0$. Nếu gán bằng 0, mô hình $\mathcal{M}_2$ sẽ có sai số bằng đúng mô hình $\mathcal{M}_1$.
- Tuy nhiên, nếu biến X_{new} có đủ chỉ một chút tương quan ngẫu nhiên (dù là nhiễu thuần túy) với biến mục tiêu Y , toán học OLS sẽ ngay lập tức lợi dụng mối tương quan này để gán cho $\hat{\beta}_{new}$ một giá trị khác 0 nhằm ép véc-tơ phần dư ngắn hơn nữa.

– Do đó, về mặt toán học ta luôn có hệ thức bất đẳng thức: $SSE_{\mathcal{M}_2} \leq SSE_{\mathcal{M}_1}$.

Vì SST là hằng số và SSE đơn điệu giảm khi số biến tăng, phân số $\frac{SSE}{SST}$ luôn luôn giảm hoặc giữ nguyên. Kéo theo chỉ số $R^2 = 1 - \frac{SSE}{SST}$ **luôn luôn tăng đơn điệu khi ta thêm biến**.

Vì thiếu đi cơ chế phạt (penalty) đối với việc gia tăng số lượng tham số, R^2 không thể kiểm soát độ phức tạp của mô hình, từ đó dễ dẫn đến hiện tượng quá khớp (overfitting) nếu được dùng làm tiêu chí lựa chọn duy nhất.

3.1.3 Ứng dụng

Là thước đo mô tả phổ biến nhất trong các báo cáo thống kê: “mô hình giải thích được X% biến thiên của Y”. Hữu ích để báo cáo kết quả cho người không chuyên.

- Ưu điểm: đơn giản, dễ hiểu, có ý nghĩa tỷ lệ rõ ràng, không cần ước lượng σ^2 riêng.
- Nhược điểm: **đơn điệu tăng** theo p nên không thể dùng so sánh các mô hình có số biến khác nhau; bị “lừa” hoàn toàn bởi biến nhiễu (Sheather 2009).

3.1.4 Khi nào dùng

Chỉ dùng R^2 để (i) báo cáo *mức độ khớp* của một mô hình đã chọn, hoặc (ii) so sánh các mô hình có **cùng số biến**. *Không bao giờ dùng R^2 làm tiêu chuẩn chọn biến*.

3.2 R^2 hiệu chỉnh (R_{adj}^2)

3.2.1 Công thức

$$R_{adj}^2 = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)} = 1 - \left(\frac{n-1}{n-p-1} \right) (1 - R^2) \quad (3)$$

- p là số biến giải thích
- $n - p - 1$ là bậc tự do còn lại sau khi ước lượng
- $p + 1$ tham số.
- Từ số $SSE/(n - p - 1) = \hat{\sigma}^2$ là **ước lượng không chệch của σ^2** ;
- Mẫu số $SST/(n - 1)$ là ước lượng không chệch của $\text{Var}(Y)$.

3.2.2 Bản chất thống kê

Cải tiến từ R^2 bằng cách dùng ước lượng không chệch của phương sai. Chỉ số này chỉ tăng nếu biến mới giúp giảm sai số đủ mạnh để bù đắp lại hình phạt mất đi bậc tự do.

- **Lack-of-fit:** Từ số SSE (Tổng bình phương sai số).
- **Penalty:** Mẫu số $(n - p - 1)$. Khi thêm biến (p tăng), mẫu số giảm, tạo áp lực đẩy giá trị phân số $SSE/(n - p - 1)$ lên cao (tức làm giảm R_{adj}^2).

3.2.2.1 Chứng minh toán học: Dẫn xuất công thức R_{adj}^2 từ lý thuyết thống kê Khai triển từng bước từ Bậc tự do (Degrees of Freedom)

- **Bước 1: Giới hạn của ước lượng phương sai trong R^2**

- Trong R^2 , phân số $\frac{SSE}{n}$ thực chất là một ước lượng chệch (biased estimator) của phương sai phần dư σ^2 , vì nó chưa trừ đi số lượng tham số $p + 1$ đã được dùng để hội tụ đường thẳng (làm mất đi bậc tự do).

- **Bước 2: Sử dụng Ước lượng Không chệch (Unbiased Estimator)**

- Theo thống kê toán, ước lượng không chệch của phương sai phần dư là: $\hat{\sigma}_{res}^2 = \frac{SSE}{n-p-1}$.
- Ước lượng không chệch của phương sai toàn phần là: $\hat{\sigma}_{tot}^2 = \frac{SST}{n-1}$.

- **Bước 3: Công thức cuối cùng của R_{adj}^2**

- Thế hai ước lượng không chệch này vào công thức gốc của R^2 , ta được:

$$R_{adj}^2 = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)}$$

Bản chất Hình phạt: Đại lượng $(n-p-1)$ ở mẫu số đóng vai trò là “hình phạt”. Khi p tăng lên, $(n-p-1)$ nhỏ lại, làm phân số $\frac{SSE}{n-p-1}$ bị đẩy giá trị lên cao (kéo R_{adj}^2 giảm xuống). Chỉ khi biến mới đủ tốt làm SSE giảm một lượng áp đảo thì R_{adj}^2 mới có thể tăng.

3.2.3 Ứng dụng

Là tiêu chuẩn chọn biến truyền thống trong các phần mềm hồi quy cổ điển.


- Ưu điểm: dễ tính, không cần ước lượng σ^2 từ mô hình đầy đủ, giữ thang đo trực quan $[0, 1]$.
- Nhược điểm: penalty $1/(n-p-1)$ *tăng chậm*, ngưỡng $F = 1$ rất “dễ dãi” — trong thực tế R_{adj}^2 **vẫn có xu hướng chọn mô hình quá lớn**; không có nền tảng lý thuyết hợp lý cực đại / Bayes như C_p , AIC, BIC.

3.2.4 Nguyên lý lựa chọn biến tối ưu dựa trên R^2 hiệu chỉnh

Nguyên lý hoạt động trên đồ thị: Khi áp dụng các thuật toán lựa chọn biến (như Forward, Backward hoặc Stepwise) và biểu diễn R_{adj}^2 theo số lượng tham số p , đồ thị thường có dạng hình chữ Parabol với 3 giai đoạn:

- Giai đoạn tăng trưởng: Khi đưa các biến có ý nghĩa thống kê cao vào mô hình, lượng sai số (SSE) giảm mạnh, áp đảo sự sụt giảm của bậc tự do, khiến R_{adj}^2 tăng nhanh.
- Điểm tối ưu (Cực đại): Đạt được khi thuật toán tìm ra tập con (subset size) cân bằng tốt nhất giữa khả năng giải thích dữ liệu và độ phức tạp của mô hình.

- Giai đoạn suy giảm: Nếu mô hình tiếp tục được bổ sung các biến không mang lại giá trị thông tin đáng kể, mức độ giảm của SSE sẽ không đủ bù đắp cho hình phạt từ việc mất đi bậc tự do. Khi đó, tỷ số trong công thức tăng lên làm cho R_{adj}^2 quay đầu giảm.



Trong quá trình lựa chọn biến, nguyên lý tối ưu của R_{adj}^2 là tìm kiếm cực đại toàn cục. Nhờ vào thành phần phạt độ phức tạp thông qua bậc tự do ($n - p - 1$), R_{adj}^2 có khả năng đạt được một điểm dừng tự nhiên tại một số lượng biến tối ưu, từ đó khắc phục được xu hướng tăng đơn điệu của R^2 . Điểm cao nhất của R_{adj}^2 chính là ngưỡng dừng toán học lý tưởng, cho biết mô hình đã đạt đến giới hạn giải thích thông tin mà không thu nạp thêm các nhiễu ngẫu nhiên.

Phù hợp khi (i) chỉ cần một sàng lọc *thô* để loại biến rõ ràng không quan trọng; (ii) muốn duy trì cách diễn giải theo tỷ lệ “% biến thiên giải thích” trong báo cáo; (iii) n vừa phải, không quá nhỏ.

Không khuyến nghị làm tiêu chuẩn duy nhất khi mục tiêu là *dự báo*.

3.3 Mallows' C_p

3.3.1 Công thức

Mallows' C_p giải quyết nhược điểm của R^2 bằng cách đi tìm một ước lượng không chệch cho sai số ngoài tập mẫu thực tế.

$$C_p = \frac{1}{n}(\text{SSE} + 2k\hat{\sigma}^2) \quad (4)$$

hoặc dạng tương đương (dùng để vẽ đồ thị chẩn đoán):

$$C_p^* = \frac{\text{SSE}}{\hat{\sigma}^2} + 2k - n. \quad (5)$$

- n : cỡ mẫu — số quan sát trong tập dữ liệu.
- $k = p + 1$: số tham số cần ước lượng trong mô hình con (p hệ số góc + 1 hệ số chặn β_0).
- $\hat{\sigma}^2$: ước lượng không chệch của σ^2 lấy từ mô hình **đầy đủ** (chứa tất cả các biến ứng viên).

Hai công thức (4) và (5) tương đương trong việc xếp hạng mô hình (rank-preserving), nhưng được dùng cho hai mục đích khác nhau:

- **Công thức (4)** (C_p , chia n): Là ước lượng trực tiếp của **test MSE** (bình phương sai số trung bình ngoài mẫu), có đơn vị giống với Y^2/n . Dùng khi muốn chọn mô hình bằng cách **tìm giá trị nhỏ nhất** — mô hình nào có C_p nhỏ nhất thì được chọn. Đây là dạng phổ biến trong ISL (James et al. 2023).
- **Công thức (5)** (C_p^* , không chia n): Là dạng gốc của Mallows (1973), thuận tiện cho **vẽ đồ thị chẩn đoán**: khi mô hình không bị bias (đúng), $\mathbb{E}[C_p^*] \approx k$, nên vẽ đồ thị C_p^* theo k (hay p) và tìm điểm nào **nằm gần đường tham chiếu** $y = k$ nhất. Dạng này thường xuất hiện trong Sheather (2009) và Weisberg (2014).

Mối quan hệ giữa hai công thức: $C_p^* = \frac{n}{\hat{\sigma}^2}C_p - n$, hay $C_p = \frac{\hat{\sigma}^2(C_p^* + n)}{n}$. Khi mô hình không bias, $C_p^* \approx k$ tương đương với $C_p \approx \frac{(k+n)\hat{\sigma}^2}{n} \approx \hat{\sigma}^2$ (với $n \gg k$).

3.3.1.1 Chứng minh toán học: Dẫn xuất công thức Mallows' C_p từ lý thuyết thống kê (góc nhìn Bias-Variance)

• Bước 1: Phân tích cấu trúc sai số thực tế

- Sai số thực tế khi đem mô hình dự báo cho một tập dữ liệu mới (Test MSE) được định nghĩa qua kỳ vọng toán học:

$$Err_{test} = \frac{1}{n} \sum_{i=1}^n E[(Y_{new,i} - \hat{Y}_i)^2]$$

- Khai triển đại lượng này bằng cách chèn giá trị kỳ vọng thực tế $E[Y_i] = \mu_i$, ta thu được phương trình cân bằng:

$$Err_{test} = E[Err_{train}] + \frac{2}{n} \sum_{i=1}^n Cov(\hat{Y}_i, Y_i)$$

- Trong đó $Err_{train} = \frac{\text{SSE}}{n}$ là sai số tính trên tập huấn luyện. Thành phần $\frac{2}{n} \sum Cov(\hat{Y}_i, Y_i)$ chính là cái giá toán học của sự lạc quan thái quá (Optimism).

• **Bước 2: Chứng minh giá trị Hiệp phương sai qua Ma trận Mũ (Hat Matrix)**

- Trong hồi quy OLS, véc-tơ giá trị dự báo được tính bằng phép chiếu tuyến tính: $\hat{Y} = HY$, với $H = X(X^T X)^{-1} X^T$.
- Xét riêng từng tọa độ dự báo: $\hat{Y}_i = \sum_{j=1}^n H_{ij} Y_j$.
- Tính toán hiệp phương sai giữa dự báo $\hat{Y}_i$ và thực tế Y_i :

$$Cov(\hat{Y}_i, Y_i) = Cov\left(\sum_{j=1}^n H_{ij} Y_j, Y_i\right) = \sum_{j=1}^n H_{ij} Cov(Y_j, Y_i)$$

- Vì các quan sát Y_i độc lập với nhau, nên $Cov(Y_j, Y_i) = 0$ với mọi $j \neq i$, và $Cov(Y_i, Y_i) = Var(Y_i) = \sigma^2$. Do đó, phương trình rút gọn thành:

$$Cov(\hat{Y}_i, Y_i) = H_{ii} \sigma^2$$

• **Bước 3: Sử dụng tính chất Vết (Trace) của Ma trận Chiếu**

- Tổng các hiệp phương sai trên toàn bộ n quan sát sẽ là:

$$\sum_{i=1}^n Cov(\hat{Y}_i, Y_i) = \sum_{i=1}^n H_{ii} \sigma^2 = \text{Tr}(H) \sigma^2$$

- Theo đại số tuyến tính, ma trận chiếu H lên không gian của mô hình hồi quy Y theo $X_1, \dots, X_p$ (có intercept) có vết đúng bằng số chiều của không gian đó, tức bằng **số tham số ước lượng** $k = p + 1$: $\text{Tr}(H) = k$.
- Do đó: $\sum_{i=1}^n Cov(\hat{Y}_i, Y_i) = k \sigma^2$.

• **Bước 4: Thiết lập chỉ số Mallows' C_p**

- Thế kết quả hiệp phương sai vào phương trình ở Bước 1: $Err_{test} \approx \frac{SSE}{n} + \frac{2k\sigma^2}{n}$.
- Nhân cả hai vế với n và thay thế hằng số chưa biết σ^2 bằng ước lượng không chệch từ mô hình đầy đủ $\hat{\sigma}^2$, ta có công thức Mallows' C_p :

$$C_p = \frac{1}{n} (SSE + 2k\hat{\sigma}^2)$$

3.3.2 Bản chất thống kê: ước lượng không chệch của test MSE

C_p là ước lượng không chệch của sai số dự báo thực tế ngoài tập mẫu (Test MSE) theo Mallows (1973). Do đó C_p càng thấp càng tốt (do sai số càng thấp tức mô hình giải thích càng tốt).

- **Lack-of-fit:** Đại lượng SSE (độ lệch/sai số trên tập huấn luyện).
- **Penalty:** Đại lượng $2k\hat{\sigma}^2$. Phạt tuyến tính theo **số tham số** $k = p + 1$ và độ nhiễu $\hat{\sigma}^2$.

Bản chất: Khi tăng số biến p lên, phần sai số SSE sẽ giảm (do thêm biến giải thích). Tuy nhiên, đại lượng $2k\hat{\sigma}^2 = 2(p + 1)\hat{\sigma}^2$ tăng khi p tăng. Chỉ khi biến mới có ý nghĩa giải thích tốt, SSE sẽ giảm mạnh, bù trừ phần tăng của $2k\hat{\sigma}^2$, làm C_p giảm. Ngược lại, nếu thêm biến không có ý nghĩa, SSE giảm không đáng kể trong khi $2k\hat{\sigma}^2$ vẫn tăng, dẫn đến C_p cao hơn.

3.3.3 Ứng dụng

- Ưu điểm: ý nghĩa thống kê rõ ràng (ước lượng test MSE), có thước đo *tuyệt đối* để chẩn đoán bias (vị trí so với $y = p$).
- Nhược điểm: cần $\hat{\sigma}^2$ từ mô hình đầy đủ — nếu mô hình đầy đủ *vẫn* thiếu biến quan trọng thì $\hat{\sigma}^2$ chệch lên và C_p không còn không chệch; chỉ hợp lệ cho **hồi quy tuyến tính Y theo $X_1, \dots, X_p$ (Gauss)** với phương sai đồng nhất.

3.3.4 Nguyên lý lựa chọn biến tối ưu dựa trên Mallows' C_p

Nguyên lý chọn subset size: Theo Akaike (1973), đã chứng minh dựa trên Khoảng cách **Kullback-Leibler** rằng khi ta thêm các biến không cần thiết vào mô hình, khoảng cách giữa phân phối mô hình dự báo và phân phối thực tế sẽ tăng lên, tạo ra hình dạng chữ U. Đáy của chữ U chính là điểm cực tiểu của C_p , nên sẽ chọn subset size tại điểm này.

Ngoài ra theo công thức C_p^* , tiêu chuẩn chọn là tìm số tham số k (hay số biến p) nhỏ nhất sao cho giá trị của C_p^* giảm và chạm vào đường tham chiếu $y = k$. (Tức khi $C_p^* \approx k$ — mô hình không chệch (unbiased))


Đặt $\text{MSE}_{\text{test}} = \mathbb{E}[(Y^* - \hat{Y}^*)^2]$.

Có thể chứng minh training SSE *chệch xuống* so với $n \cdot \text{MSE}_{\text{test}}$ một lượng xấp xỉ $2k\sigma^2$ (gọi là *optimism*). Mallows (1973) đề xuất *cộng trả lại* đúng độ chệch đó:

$$\mathbb{E}\left[\frac{1}{n}(\text{SSE} + 2k\hat{\sigma}^2)\right] \approx \text{MSE}_{\text{test}}.$$

Do đó C_p là **ước lượng không chệch của test MSE** khi $\hat{\sigma}^2$ không chệch. Với mô hình “đúng” (không bias), $\mathbb{E}(C_p^*) \approx k$ — quy tắc thực hành: chọn mô hình có C_p^* gần đường $y = k$ nhất.

Biểu đồ Mallows' C_p cho dữ liệu Diabetes



Sử dụng khi: (i) bài toán là **hồi quy tuyến tính** Y theo $X_1, \dots, X_p$ (**Gauss cổ điển**);

(ii) n đủ lớn để $\hat{\sigma}^2$ ổn định; (iii) muốn có thước đo trực quan với “đường tham chiếu” $y = k$ để nhận diện bias. Với GLM, hỗn hợp, ... không dùng C_p mà chuyển sang AIC.

3.4 AIC — Akaike Information Criterion

AIC không đi từ phương sai như C_p , mà đi từ **Khoảng cách Kullback-Leibler** (khoảng cách giữa phân phối thực tế của dữ liệu và phân phối do mô hình dự báo).

3.4.1 Công thức và dẫn xuất

$$\text{AIC} = -2 \ln L + 2k$$

- L : Hàm hợp lý (Likelihood Function).
- $k = p + 1$: Số tham số cần ước lượng trong mô hình hồi quy Y theo $X_1, \dots, X_p$ (gồm p hệ số góc và 1 hệ số chặn β_0).

Trong hồi quy tuyến tính Y theo $X_1, \dots, X_p$ (Gauss), quy đổi tỷ lệ thuận thành dạng tương tự C_p :

$$\text{AIC} \approx \frac{1}{n\hat{\sigma}^2} (\text{SSE} + 2k\hat{\sigma}^2)$$

Bước 1: Hàm Hợp lý Cực đại (Log-Likelihood) Giả sử sai số có phân phối chuẩn, hàm Log-Likelihood của mô hình tuyến tính là:

$$\ln L(\hat{\beta}, \hat{\sigma}^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\hat{\sigma}^2) - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (y_i - X_i \hat{\beta})^2$$

$$\ln L = C - \frac{n}{2} \ln(\hat{\sigma}^2) - \frac{SSE}{2\hat{\sigma}^2}$$

Bước 2: Nguyên lý Akaike Hirotugu Akaike chứng minh rằng giá trị lớn nhất của Log-likelihood trên tập Training là một ước lượng chệch của “lượng thông tin thực sự”. Độ chệch này xấp xỉ bằng **số tham số cần ước lượng** $k = p + 1$. Công thức AIC tiêu chuẩn:

$$AIC = -2 \ln L + 2k$$

Bước 3: Quy đổi AIC về dạng SSE trong hồi quy tuyến tính Y theo $X_1, \dots, X_p$ Bỏ qua các hằng số không ảnh hưởng đến việc so sánh, nếu giả định $\hat{\sigma}^2$ là hằng số cố định (ước lượng từ mô hình đầy đủ), thế $\ln L$ vào, ta được dạng xấp xỉ tỷ lệ:

$$AIC \propto \frac{1}{n\hat{\sigma}^2} (SSE + 2k\hat{\sigma}^2)$$

3.4.2 Bản chất thống kê: xấp xỉ Kullback–Leibler

Xuất phát từ lý thuyết thông tin, AIC xấp xỉ khoảng cách Kullback-Leibler để tìm mô hình gần nhất với cơ chế sinh dữ liệu. Trong hồi quy tuyến tính Y theo $X_1, \dots, X_p$ (Gauss), AIC tương đương hoàn toàn với Mallows’ C_p .

- **Lack-of-fit:** Đại lượng $-2 \ln L$ (hoặc tương đương SSE).
- **Penalty:** Đại lượng $2k$ (hoặc tương đương $2k\hat{\sigma}^2$). Mức phạt cố định bằng 2 cho mỗi tham số cần ước lượng $k = p + 1$.

3.4.3 Ứng dụng

Áp dụng được cho mọi mô hình MLE: GLM, hỗn hợp, time series, sống còn ... — đây là điểm mạnh quan trọng nhất so với C_p .

- Ưu điểm: cơ sở lý thuyết vững (K–L); áp dụng được rất rộng; **hiệu quả tiệm cận** — khi $n \rightarrow \infty$, sai số dự báo của mô hình do AIC chọn tiến tới sai số của mô hình tốt nhất có thể.
- Nhược điểm: khi n nhỏ AIC *thiên về mô hình lớn* (penalty $2K$ không đủ mạnh); nếu mô hình thật thực sự nằm trong tập ứng viên, AIC *không nhất quán* — xác suất chọn đúng không tiến tới 1.

3.4.4 Nguyên lý lựa chọn biến tối ưu dựa trên AIC


Nguyên lý chọn subset size: Khoảng cách Kullback–Leibler đo lường “mức độ mất mát thông tin” giữa phân phối thật f và mô hình g :

$$KL(f \parallel g) = \mathbb{E}_f \left[\log \frac{f(Y)}{g(Y | \theta)} \right].$$

- $f(Y)$: phân phối xác suất thật của dữ liệu.
- $g(Y | \theta)$: likelihood mà model gán cho dữ liệu Y
- $E_f[\cdot]$: Kỳ vọng theo phân phối thật f

Để mô hình tốt nhất, ta phải chọn θ sao cho khoảng cách K-L là cực tiểu. Tức $\mathbb{E}_f[\log g(Y | \hat{\theta})]$ đạt cực đại
→ $-2\mathbb{E}_f[\log g(Y | \hat{\theta})]$ phải nhỏ nhất.

Sự biến thiên của AIC theo số lượng biến



AIC chính là **xấp xỉ không chệch** của $-2\mathbb{E}_f[\log g(Y | \hat{\theta})]$, cộng với một hằng số không phụ thuộc mô hình. Mô hình có AIC nhỏ nhất là mô hình *gần nhất* với cơ chế sinh dữ liệu theo nghĩa K–L. Trong hồi quy tuyến tính Y theo $X_1, \dots, X_p$ (Gauss), AIC và C_p **tỷ lệ tuyến tính** — chọn cùng một mô hình.

Khi (i) mục tiêu chính là **dự báo / mô hình hoá hiện tượng**, không phải tìm “mô hình thật”; (ii) tin rằng không có mô hình ứng viên nào *đúng* — chỉ là xấp xỉ; (iii) muốn tiêu chuẩn áp dụng được ngoài phạm vi hồi quy tuyến tính. Với $n/k < 40$, dùng $AIC_C = AIC + \frac{2k(k+1)}{n-k-1}$ (Hurvich & Tsai 1989) (Sheather 2009)

3.5 BIC — Bayesian Information Criterion

BIC tiếp cận bài toán chọn biến dưới góc nhìn hoàn toàn khác: Xác suất Hậu nghiệm của Bayes. Điểm mấu chốt cấu thành nên hình phạt $\log(n)$ phức tạp của BIC chính là kỹ thuật toán học mang tên **Xấp xỉ Laplace (Laplace Approximation)**.

3.5.1 Bổ sung kiến thức: Xấp xỉ Laplace

- Trong thống kê Bayes, khi ta muốn tính xác suất của một mô hình, ta phải tính một tích phân khổng lồ trên không gian nhiều chiều để loại bỏ các tham số nhiễu (gọi là Marginal Likelihood). Tích phân này thường không có nghiệm giải tích (không tính trực tiếp được).
- **Ý tưởng của Laplace:** Khi kích thước mẫu n tiến ra vô cùng ($n \rightarrow \infty$), theo định lý giới hạn trung tâm, hàm mật độ xác suất hậu nghiệm sẽ hội tụ và co cụm lại cực kỳ nhọn xung quanh một điểm duy nhất là điểm cực đại (điểm MAP hoặc ước lượng hợp lý cực đại MLE $\hat{\theta}$).
- Vì đồ thị hàm số lúc này trông giống hệt như một chiếc chuông chuẩn (Gaussian), Laplace đề xuất thay thế toàn bộ hàm số phức tạp dưới dấu tích phân bằng một hàm mũ bậc hai (Phân phối chuẩn) tương đương tại đỉnh để tính toán tích phân một cách dễ dàng.

3.5.2 Công thức

BIC được thiết kế để chọn mô hình có xác suất hậu nghiệm cao nhất trong số các mô hình ứng viên. Xác suất này được tính bằng cách tích phân toàn bộ không gian tham số θ để loại bỏ sự phụ thuộc vào các tham số không quan trọng, chỉ giữ lại thông tin về mô hình và dữ liệu.

Schwarz (1978):

$$\text{BIC} = -2 \log L(\hat{\theta} | Y) + k \log n \quad (9)$$

Với hồi quy tuyến tính Y theo $X_1, \dots, X_p$ (Gauss):

$$\text{BIC} = n \log \left(\frac{\text{SSE}}{n} \right) + k \log n. \quad (10)$$

- n : cỡ mẫu — tổng số quan sát trong bộ dữ liệu.
- $k = p + 1$: số tham số cần ước lượng (gồm p hệ số góc và hệ số chặn β_0).

3.5.2.1 Chứng minh toán học: Dẫn xuất công thức BIC từ lý thuyết thống kê (góc nhìn Xấp xỉ Laplace)

- **Bước 0: Mục tiêu của BIC**
- **Bước 1: Thiết lập tích phân Hàm hợp lý biên**

– Xác suất để dữ liệu được sinh ra từ mô hình $\mathcal{M}$ được tính bằng tích phân:

$$P(\text{Data} | \mathcal{M}) = \int \exp(\ln P(\text{Data} | \theta, \mathcal{M})) P(\theta | \mathcal{M}) d\theta$$

– Ký hiệu hàm log-likelihood là $L_n(\theta) = \ln P(\text{Data} | \theta, \mathcal{M})$.

• **Bước 2: Khai triển Taylor bậc hai tại điểm cực đại $\hat{\theta}$**

- Khai triển chuỗi Taylor của hàm $L_n(\theta)$ xung quanh điểm ước lượng hợp lý cực đại $\hat{\theta}$:

$$L_n(\theta) \approx L_n(\hat{\theta}) + \nabla L_n(\hat{\theta})^T (\theta - \hat{\theta}) + \frac{1}{2} (\theta - \hat{\theta})^T \nabla^2 L_n(\hat{\theta}) (\theta - \hat{\theta})$$

- Vì $\hat{\theta}$ là điểm cực đại (đỉnh parabol), nên đạo hàm bậc nhất tại đây bằng không: $\nabla L_n(\hat{\theta}) = 0$. Thành phần thứ hai biến mất.
- Gọi ma trận đạo hàm bậc hai (Ma trận Hessian) tại đỉnh là $H = -\nabla^2 L_n(\hat{\theta})$. Hàm số rút gọn thành:

$$L_n(\theta) \approx L_n(\hat{\theta}) - \frac{1}{2} (\theta - \hat{\theta})^T H (\theta - \hat{\theta})$$

• **Bước 3: Thực hiện tích phân Gauss (Gaussian Integration)**

- Thế hàm xấp xỉ Taylor vào dấu tích phân ban đầu, đưa hằng số $\exp(L_n(\hat{\theta}))$ ra ngoài:

$$P(Data|\mathcal{M}) \approx \exp(L_n(\hat{\theta})) \int \exp\left(-\frac{1}{2}(\theta - \hat{\theta})^T H (\theta - \hat{\theta})\right) P(\theta|\mathcal{M}) d\theta$$

- Khi n rất lớn, phân phối Prior $P(\theta|\mathcal{M})$ coi như phẳng và hằng số so với sự nhọn của đỉnh hàm hợp lý, ta đưa nó ra ngoài như một hằng số.
- Phần tích phân còn lại chính là dạng tích phân Gauss đa biến chuẩn hóa trên không gian k chiều (tương ứng k tham số trong θ). Kết quả toán học của tích phân này bằng:

$$\int \exp\left(-\frac{1}{2}(\theta - \hat{\theta})^T H (\theta - \hat{\theta})\right) d\theta = \frac{(2\pi)^{k/2}}{\sqrt{\det(H)}}$$

- Suy ra: $P(Data|\mathcal{M}) \approx \exp(L_n(\hat{\theta})) \cdot \frac{(2\pi)^{k/2}}{\sqrt{\det(H)}} \cdot P(\hat{\theta}|\mathcal{M})$

• **Bước 4: Lấy Log tự nhiên để phá bỏ hàm mũ**

$$\ln P(Data|\mathcal{M}) \approx L_n(\hat{\theta}) - \frac{1}{2} \ln \det(H) + \frac{k}{2} \ln(2\pi) + \ln P(\hat{\theta}|\mathcal{M})$$

• **Bước 5: Cô lập kích thước mẫu n để rút gọn tiệm cận**

- Ma trận Hessian H tổng hợp thông tin từ n quan sát độc lập, do đó mỗi phần tử của ma trận H tăng trưởng tuyến tính theo n . Ta có thể viết $H = n \cdot \mathcal{J}$, trong đó $\mathcal{J}$ là ma trận thông tin Fisher trung bình trên một quan sát.
- Sử dụng tính chất của định thức ma trận vuông cấp k ($=$ số tham số): $\det(H) = \det(n \cdot \mathcal{J}) = n^k \cdot \det(\mathcal{J})$.
- Lấy logarit cho định thức này:

$$\ln \det(H) = \ln(n^k \cdot \det(\mathcal{J})) = k \ln(n) + \ln \det(\mathcal{J})$$

- Thế ngược lại vào phương trình Bước 4 và gom tất cả các thành phần không phụ thuộc vào n (như $\ln \det(\mathcal{J})$, $\ln(2\pi)$) thành hằng số $O(1)$:

$$\ln P(Data|\mathcal{M}) \approx L_n(\hat{\theta}) - \frac{k}{2} \ln(n) + O(1)$$

- **Bước 6: Định hình chỉ số BIC hoàn chỉnh**

- Để đồng bộ với AIC (bài toán tìm giá trị nhỏ nhất), ta nhân toàn bộ phương trình với -2 :

$$BIC = -2L_n(\hat{\theta}) + k \ln(n)$$

- Trong điều kiện hồi quy tuyến tính Y theo $X_1, \dots, X_p$ (chuẩn), $-2L_n(\hat{\theta})$ quy đổi tỷ lệ tương đương với $\frac{SSE}{\hat{\sigma}^2}$, dẫn đến hệ thức phạt quen thuộc:

$$BIC \propto \frac{1}{n\hat{\sigma}^2}(SSE + \ln(n) \cdot k \cdot \hat{\sigma}^2)$$

Hệ số $\log(n)$ của BIC là kết quả tất yếu trích xuất từ **định thức của ma trận thông tin đạo hàm bậc hai khi thực hiện xấp xỉ hình học chuông Laplace** cho hàm xác suất.

3.5.3 Bản chất thống kê: xấp xỉ Bayes marginal likelihood

Dựa trên xác suất hậu nghiệm Bayes, BIC tìm kiếm mô hình “đúng” nhất sinh ra dữ liệu. Mức phạt của BIC trích xuất từ xấp xỉ Laplace của hàm hợp lý biên, rất khắt khe khi mẫu n lớn.

- **Lack-of-fit:** Đại lượng $-2 \ln L$ (hoặc tương đương SSE).
- **Penalty:** Đại lượng $k \log(n)$ (hoặc tương đương $k \log(n)\hat{\sigma}^2$) với $k = p + 1$. Hình phạt tăng trưởng theo hàm logarit của n .

BIC xuất phát từ *xấp xỉ Laplace* của marginal likelihood $P(Y | M_i)$ — xác suất hậu nghiệm của mô hình M_i với tiên nghiệm đều trên tập mô hình. Khi $n \rightarrow \infty$, $-2 \log P(Y | M_i) \approx BIC_i + O(1)$.

Đặt $\Delta BIC_i = BIC_i - \min_j BIC_j$:

$$P(M_i | \text{data}) \approx \frac{\exp(-\Delta BIC_i/2)}{\sum_r \exp(-\Delta BIC_r/2)}.$$

Đây là cách diễn giải xác suất *rất tự nhiên* — không có ở AIC hay C_p .

3.5.4 Ứng dụng

Phổ biến trong: chọn mô hình thống kê *giải thích* (econometrics, biostat), chọn số cụm trong mixture model, chọn bậc trong time series, model averaging (qua ΔBIC).


- Ưu điểm: có diễn giải Bayes; **nhất quán** — nếu mô hình thật thuộc tập ứng viên, $P(\text{BIC chọn đúng}) \rightarrow 1$ khi $n \rightarrow \infty$; chọn mô hình *gọn*, dễ trình bày khoa học.
- Nhược điểm: với n nhỏ, penalty $\log n$ có thể *quá mạnh* và loại bỏ biến hữu ích; giả định “mô hình thật nằm trong tập ứng viên” thường không thực tế — khi đó tính nhất quán mất ý nghĩa và AIC hoạt động tốt hơn (Yang, 2005).

3.5.5 Nguyên lý lựa chọn biến tối ưu dựa trên BIC

Nguyên lý chọn subset size: Cũng giống như AIC, khi thêm biến thì giảm SSE. Tuy nhiên, nếu dữ liệu có số mẫu lớn sẽ cộng thêm $k \log(n)$ giá trị. Nếu cỡ mẫu $n = 1000$ thì $\log(1000) \approx 6.9$, tức mỗi tham số thêm vào bị phạt xấp xỉ 7 đơn vị — mạnh hơn AIC (phạt 2 mỗi tham số) khoảng 3.5 lần.

Chọn mô hình có BIC nhỏ nhất tức là biến mới đưa vào phải cực kỳ có ý nghĩa, giúp SSE giảm một lượng lớn để bù cho phần tăng thêm của $\log(n)$.

Sự biến thiên của BIC theo số lượng biến



Sử dụng khi (i) mục tiêu là **giải thích / xác định mô hình đúng** (causal-inspired, khoa học cơ bản);

(ii) n tương đối lớn ($n \geq 30$ là tối thiểu thực hành);

(iii) cần một mô hình *gọn, ít biến* để diễn giải;

(iv) muốn báo cáo *xác suất hậu nghiệm* mô hình.

3.6 Khi nào dùng tiêu chuẩn nào?

Tiêu chuẩn	Penalty	Mục tiêu	Tính chất
R^2	0 (đơn điệu)	Mô tả khớp	Không dùng chọn biến
R_{adj}^2	$1/(n - p - 1)$ ảm	Giải thích thô	Yếu — xu hướng over-fit
C_p	$+2k\hat{\sigma}^2$	Dự báo (Gauss)	Ước lượng test MSE
AIC	$+2k$	Dự báo (mọi MLE)	Hiệu quả tiệm cận
BIC	$+k \log n$	Mô hình "đúng"	Nhất quán
$k = p + 1 = \text{số tham số ước lượng (số biến giải thích + hệ số chặn } \beta_0)$			

Hai trục quyết định:

1. Mục tiêu là dự báo hay giải thích? Dự báo $\Rightarrow$ AIC / C_p . Giải thích / tìm "true model" $\Rightarrow$ BIC.

2. Phạm vi mô hình. Hồi quy tuyến tính Y theo $X_1, \dots, X_p$ (Gauss) thuần túy $\Rightarrow$ có thể dùng C_p (có "đường tham chiếu" $y = k$). Mô hình tổng quát hơn (GLM, hỗn hợp, ...) $\Rightarrow$ AIC hoặc BIC.

Trong thực hành, các tác giả như Burnham & Anderson (2004) khuyến nghị **không chọn cứng** theo một tiêu chuẩn duy nhất mà *liệt kê* mô hình được mỗi tiêu chuẩn ưu tiên, đối chiếu với chẩn đoán dư (residual diagnostics) và tính diễn giải, rồi chọn mô hình *đơn giản nhất nằm trong vùng "tốt"* của tất cả các tiêu chuẩn — nguyên lý **parsimony** (tiết kiệm).

Trên thực tế, các tiêu chuẩn trên có thể đưa ra những mô hình tối ưu khác nhau. Để minh họa sự khác biệt này, tiến hành áp dụng phương pháp Best Subset Selection trên bộ dữ liệu diabetes và tổng hợp kết quả lựa chọn mô hình theo từng tiêu chuẩn.

3.7 Tổng hợp kết quả lựa chọn biến theo các tiêu chuẩn

```
best_subset <- regsubsets(target ~ ., data = train_data, nvmax = 10)
best_summary <- summary(best_subset)

# Tính AIC cho mô hình tốt nhất ở từng số lượng biến
aic_values <- numeric(10)

for (i in 1:10) {
  vars_i <- names(coef(best_subset, i))[-1]
  formula_i <- as.formula(paste("target ~", paste(vars_i, collapse = " + ")))
  model_i <- lm(formula_i, data = train_data)
  aic_values[i] <- AIC(model_i)
}

# table tổng hợp các criteria
criteria_table <- data.frame(
  Subset_size = 1:10,
  R2 = best_summary$rsq,
  Adj_R2 = best_summary$adjr2,
  Cp = best_summary$cp,
  AIC = aic_values,
```



```
BIC = best_summary$bic
)
```

```
round(criteria_table, 4)
```

##	Subset_size	R2	Adj_R2	Cp	AIC	BIC
## 1	1	0.3232	0.3213	120.9207	3935.563	-126.0862
## 2	2	0.4385	0.4353	42.8747	3871.644	-186.1384
## 3	3	0.4690	0.4644	23.7272	3853.958	-199.9582
## 4	4	0.4805	0.4745	17.7104	3848.199	-201.8513
## 5	5	0.4972	0.4900	8.0886	3838.638	-207.5454
## 6	6	0.5037	0.4951	5.6325	3836.103	-206.2140
## 7	7	0.5073	0.4973	5.1116	3835.511	-202.9391
## 8	8	0.5073	0.4959	7.0790	3837.478	-197.1063
## 9	9	0.5074	0.4945	9.0358	3839.433	-191.2844
## 10	10	0.5075	0.4931	11.0000	3841.396	-185.4549

Bảng tóm tắt mô hình tối ưu theo từng tiêu chí:

```
best_r2_size <- which.max(best_summary$rsq)
best_adjr2_size <- which.max(best_summary$adjr2)
best_cp_size <- which.min(best_summary$cp)
best_aic_size <- which.min(aic_values)
best_bic_size <- which.min(best_summary$bic)

vars_r2 <- names(coef(best_subset, best_r2_size))[-1]
vars_adjr2 <- names(coef(best_subset, best_adjr2_size))[-1]
vars_cp <- names(coef(best_subset, best_cp_size))[-1]
vars_aic <- names(coef(best_subset, best_aic_size))[-1]
vars_bic <- names(coef(best_subset, best_bic_size))[-1]

best_model_summary <- data.frame(
  Criterion = c(
    "R2 lớn nhất",
    "R2 hiệu chỉnh lớn nhất",
    "Cp nhỏ nhất",
    "AIC nhỏ nhất",
    "BIC nhỏ nhất"
  ),
  Subset_size = c(
    best_r2_size,
    best_adjr2_size,
    best_cp_size,
    best_aic_size,
    best_bic_size
  ),
)
```

```

Predictors = c(
  paste(vars_r2, collapse = ", "),
  paste(vars_adj2, collapse = ", "),
  paste(vars_cp, collapse = ", "),
  paste(vars_aic, collapse = ", "),
  paste(vars_bic, collapse = ", ")
),
Value = c(
  round(max(best_summary$rsq), 4),
  round(max(best_summary$adjr2), 4),
  round(min(best_summary$cp), 4),
  round(min(aic_values), 4),
  round(min(best_summary$bic), 4)
)
)

knitr::kable(best_model_summary,
  caption = "Mô hình tối ưu theo từng tiêu chuẩn")

```

Table 1: Mô hình tối ưu theo từng tiêu chuẩn

Criterion	Subset_size	Predictors	Value
R2 lớn nhất	10	age, sex, bmi, map, tc, ldl, hdl, tch, ltg, glu	0.5075
R2 hiệu chỉnh lớn nhất	7	sex, bmi, map, tc, ldl, ltg, glu	0.4973
Cp nhỏ nhất	7	sex, bmi, map, tc, ldl, ltg, glu	5.1116
AIC nhỏ nhất	7	sex, bmi, map, tc, ldl, ltg, glu	3835.5113
BIC nhỏ nhất	5	sex, bmi, map, hdl, ltg	-207.5454

Kết quả trên cho thấy mỗi tiêu chuẩn có thể lựa chọn mô hình khác nhau. Tiêu chuẩn R^2 có xu hướng chọn mô hình nhiều biến nhất vì R^2 không giảm khi thêm biến vào mô hình. Trong khi đó, Adjusted R^2 , Mallows' C_p , AIC và BIC đều có cơ chế phạt đối với độ phức tạp của mô hình nên thường lựa chọn các mô hình gọn hơn.

Đối với bộ dữ liệu diabetes, các mô hình được lựa chọn bởi Adjusted R^2 , C_p , AIC và BIC có số lượng biến tương đối gần nhau. Điều này cho thấy các biến được lựa chọn có mức độ ổn định nhất định và chứa phần lớn thông tin cần thiết để giải thích biến phản hồi. Các kết quả này sẽ được sử dụng để đối chiếu với các thủ tục lựa chọn biến ở phần tiếp theo.

4 Các phương pháp lựa chọn mô hình

Tiếp tục với dataset diabetes, dataset hiện đang có 10 biến độc lập. Vì vậy khi xem xét các mô hình, có một cách luôn mang lại một mô hình phù hợp nhất bằng cách lấy tổ hợp các biến với nhau. Như vậy, ta sẽ có tổng số:

$$\sum_{k=0}^{p-1} \binom{p-1}{k} = 2^{p-1} = 2^{10} = 1024$$

mô hình khả thi. Từ những mô hình này, áp dụng các tiêu chí đánh giá mô hình phối hợp với các kiểm định giả thuyết thống kê để chọn ra mô hình tối ưu nhất.

Giả sử nếu mô hình có 20 hoặc thậm chí 30 biến, tổng số mô hình phải chạy là rất lớn, lần lượt là $2^{20} = 1.048.576$ và $2^{30} = 1.073.741.824$ mô hình. Điều này dẫn đến gia tăng về mặt chi phí tính toán, quá tải hệ thống và tiêu tốn nhiều thời gian xử lý, khiến việc duyệt toàn bộ mô hình trở nên bất khả thi trong thực tế.

Vì vậy, một cách tiếp cận tối ưu hơn là sử dụng các quy trình tìm kiếm tuần tự như Forward (lựa chọn tiến), Backward (loại trừ lùi), hoặc Stepwise (hồi quy từng bước) để tìm kiếm không gian mô hình hiệu quả (Dalpiaz 2021).

4.1 Forward Selection (Lựa chọn tiến)

4.1.1 Nguyên lý hoạt động

Lựa chọn tiến bắt đầu với một mô hình không chứa biến dự báo nào. Sau đó, đối với tất cả các biến độc lập chưa nằm trong mô hình, thuật toán kiểm tra giá trị p -value của chúng nếu chúng được thêm vào mô hình. Biến được chọn là biến có giá trị p -value thấp nhất và nhỏ hơn mức ý nghĩa đầu vào α_{enter} . Quá trình này diễn ra liên tục cho đến khi không còn biến mới nào có thể nạp vào mô hình (Faraway 2015).

Mức ý nghĩa tới hạn α_{crit} trong việc kiểm soát điều kiện dừng đôi khi được gọi là “p-to-remove” (hoặc “p-to-enter” tùy thuộc vào thuật toán) và không nhất thiết phải cố định ở mức nào đó (mức thường được chọn là 5%). Việc lựa chọn ngưỡng này phụ thuộc vào mục tiêu của mô hình. Nếu mục tiêu là giải thích, ngưỡng 5% giúp giữ lại những biến thực sự có ý nghĩa thống kê, tạo ra mô hình gọn và dễ diễn giải. Ngược lại, nếu mục tiêu là dự báo, việc nới lỏng ngưỡng lên 15–20% cho phép giữ lại các biến có đóng góp nhỏ nhưng vẫn cải thiện độ chính xác dự báo — những biến mà nếu áp dụng ngưỡng nghiêm ngặt sẽ bị loại nhầm (Faraway 2015).

4.1.2 Thuật toán

4.1.2.1 Bắt đầu

- Xuất phát từ mô hình rỗng (Null Model). Lúc này mô hình chỉ chứa duy nhất hệ số chặn (β_0).
- Trạng thái mô hình:

$$Y = \beta_0$$

- Tập hợp biến trong mô hình (S_{in}): Rỗng ($\emptyset$).
- Tập hợp biến ngoài mô hình (S_{out}): Chứa toàn bộ các biến $\{X_1, X_2, \dots, X_p\}$.

4.1.2.2 Quy trình đi từng bước

• Bước 1: Đánh giá độc lập:

- Máy tính chạy thử nghiệm độc lập từng biến X_i thuộc tập S_{out} bằng cách bắt cặp với mô hình hiện tại.

- Đo lường mức độ cải thiện mô hình của từng biến dựa trên một tiêu chuẩn định lượng cố định (ví dụ: biến làm giảm AIC/BIC nhiều nhất, hoặc biến có p -value nhỏ nhất).
- Tìm ra biến đáp ứng được tiêu chuẩn đề ra tốt nhất, gọi là X_{best} .

• **Bước 2: Ra quyết định:**

- Nếu chỉ số của X_{best} vượt qua ngưỡng kiểm định được thiết lập trước (Ví dụ: $p\text{-value} \leq \alpha_{\text{enter}}$ hoặc $\Delta\text{AIC} < 0$), thì thuật toán chính thức nạp X_{best} vào mô hình.
- Cập nhật trạng thái: Chuyển X_{best} từ tập S_{out} sang tập S_{in} .
- Trạng thái mô hình lúc này:

$$Y = \beta_0 + \beta_{\text{best}} X_{\text{best}}$$

• **Bước 3: Lặp lại vòng lặp:**

- Cố định các biến đã ở trong tập S_{in} . Tiếp tục thử nghiệm bắt cặp với các biến còn lại trong tập S_{out} để tìm ra biến phối hợp bổ trợ tốt nhất với các biến đã được chọn từ trước.
- **Điều kiện dừng:** Nếu tại một bước nào đó, khi thử nạp bất kỳ biến nào còn lại ở ngoài vào mô hình mà không một biến nào thỏa mãn ngưỡng ý nghĩa thống kê, thì thuật toán dừng lại và đưa ra mô hình ở bước trước đó.


• **Tổng số mô hình tối đa phải tính toán:**

$$\text{Total}_{\text{Forward}} = p + (p - 1) + (p - 2) + \dots + 1 = \frac{p(p + 1)}{2}$$

Áp dụng đối với dataset diabetes:

Quá trình lựa chọn biến theo Forward Selection

Mô hình tối ưu đạt được tại bước 7



- **Diễn giải đường đi của Forward Selection**

Biểu đồ trên trực quan hóa toàn bộ quá trình thuật toán Forward Selection dựa trên tiêu chí tối ưu hóa AIC như sau:

1. **Điểm khởi đầu (Step 0 - Intercept):**

- **Trạng thái:** Thuật toán bắt đầu với một mô hình rỗng (Null Model), hoàn toàn chưa có biến độc lập nào mà chỉ chứa hệ số chặn (Intercept).
- **Giá trị AIC:** Tại bước này, AIC đạt mức cao nhất. Điều này phản ánh mô hình giải thích dữ liệu rất kém và bị mất mát thông tin nhiều nhất vì chưa có sự tham gia của các biến dự báo.

2. **Xu hướng chuyển dịch của đường đồ thị (Từ Step 1 đến Step 7):**

- **Hướng đi:** Đường đồ thị có dốc xuống rõ rệt từ trái qua phải.
- **Ý nghĩa:**
 - Qua mỗi bước, thuật toán sẽ duyệt qua toàn bộ các biến chưa có trong mô hình, tính toán và chọn ra duy nhất một biến giúp giảm chỉ số AIC nhiều nhất.
 - Ở Step 1, biến `ltg` được chọn đầu tiên, chứng tỏ đây là biến có sức mạnh giải thích lớn nhất đối với biến phụ thuộc, kéo AIC giảm mạnh.
 - Các bước tiếp theo lần lượt ghi nhận sự tham gia của `bmi`, `map`, `tc`, `sex`, `ldl`, `glu`. Tốc độ giảm của AIC có xu hướng chậm lại ở các bước cuối (`ldl` sang `glu`), cho thấy các biến thêm vào sau mang lại giá trị thông tin biên (marginal value) ít hơn so với các biến ban đầu.

3. **Điểm dừng của thuật toán:**

- Thuật toán sẽ tiếp tục “bước đi” và thêm biến cho đến khi đạt đến trạng thái bão hòa thông tin.
- **Điểm dừng tối ưu** (ở đây minh họa là Step 7 với biến `glu`) là vị trí mà tại đó, nếu thuật toán thêm biến nào đang nằm ngoài mô hình, giá trị AIC sẽ bị tăng lên thay vì giảm đi (do mô hình bị phạt vì quá cồng kềnh - hiện tượng Overfitting). Tại điểm này, đường đi dừng lại và mô hình ở Step 7 được chọn là mô hình tối ưu nhất.

4.1.3 Áp dụng

```
# Forward selection
null_model <- lm(target ~ 1, data = train_data)

forward_model <- step(
  null_model,
  scope = list(lower = null_model, upper = full_model),
  direction = "forward",
  trace = TRUE
)

## Start:  AIC=3067.61
## target ~ 1
##
```

```

##          Df Sum of Sq      RSS      AIC
## + ltg    1      674365 1411972 2931.8
## + bmi    1      650520 1435817 2937.7
## + map    1      424474 1661862 2989.3
## + glu    1      345678 1740659 3005.7
## + tch    1      329032 1757304 3009.0
## + hdl    1      281569 1804767 3018.4
## + tc     1      102448 1983888 3051.8
## + age    1       89777 1996560 3054.1
## + ldl    1       61536 2024800 3059.0
## <none>                2086336 3067.6
## + sex    1        151 2086185 3069.6
##
## Step:   AIC=2931.79
## target ~ ltg
##
##          Df Sum of Sq      RSS      AIC
## + bmi    1      240514 1171457 2867.9
## + map    1      127791 1284180 2900.3
## + hdl    1       51536 1360436 2920.7
## + glu    1       50871 1361101 2920.8
## + tc     1       16769 1395202 2929.6
## + sex    1        8172 1403799 2931.7
## <none>                1411972 2931.8
## + tch    1        7517 1404454 2931.9
## + age    1        4211 1407760 2932.7
## + ldl    1         856 1411116 2933.6
##
## Step:   AIC=2867.87
## target ~ ltg + bmi
##
##          Df Sum of Sq      RSS      AIC
## + map    1       63542 1107915 2850.2
## + tc     1       20838 1150620 2863.5
## + hdl    1       16228 1155230 2864.9
## + glu    1       14655 1156802 2865.4
## + sex    1        8940 1162517 2867.2
## + ldl    1        8035 1163422 2867.4
## <none>                1171457 2867.9
## + age    1        2166 1169292 2869.2
## + tch    1         58 1171399 2869.9
##
## Step:   AIC=2850.19
## target ~ ltg + bmi + map
##
##          Df Sum of Sq      RSS      AIC
## + tc     1      24088.1 1083827 2844.4
## + sex    1     22544.4 1085371 2844.9

```

```

## + hdl    1    16546.2 1091369 2846.9
## + ldl    1     9988.4 1097927 2849.0
## <none>                1107915 2850.2
## + glu    1     4895.2 1103020 2850.6
## + age    1      422.7 1107493 2852.1
## + tch    1      161.6 1107754 2852.1
##
## Step:  AIC=2844.43
## target ~ ltg + bmi + map + tc
##
##          Df Sum of Sq    RSS    AIC
## + sex    1   22705.5 1061122 2838.9
## + ldl    1    9434.7 1074392 2843.3
## + hdl    1    6641.6 1077186 2844.3
## + glu    1    6503.7 1077323 2844.3
## <none>                1083827 2844.4
## + tch    1    4917.2 1078910 2844.8
## + age    1      66.2 1083761 2846.4
##
## Step:  AIC=2838.95
## target ~ ltg + bmi + map + tc + sex
##
##          Df Sum of Sq    RSS    AIC
## + ldl    1   25603.7 1035518 2832.3
## + hdl    1   21103.3 1040018 2833.9
## + tch    1   17332.0 1043790 2835.1
## + glu    1   10046.1 1051076 2837.6
## <none>                1061122 2838.9
## + age    1     672.5 1060449 2840.7
##
## Step:  AIC=2832.33
## target ~ ltg + bmi + map + tc + sex + ldl
##
##          Df Sum of Sq    RSS    AIC
## + glu    1    7574.7 1027943 2831.7
## <none>                1035518 2832.3
## + age    1     693.2 1034825 2834.1
## + tch    1     278.2 1035240 2834.2
## + hdl    1        0.0 1035518 2834.3
##
## Step:  AIC=2831.74
## target ~ ltg + bmi + map + tc + sex + ldl + glu
##
##          Df Sum of Sq    RSS    AIC
## <none>                1027943 2831.7
## + age    1     97.898 1027845 2833.7
## + tch    1     80.521 1027863 2833.7
## + hdl    1      8.567 1027935 2833.7

```

```

summary_forward <- summary(forward_model)

adj_r2 <- summary_forward$adj.r.squared #R2 adj

# Mallows' Cp
rss_forward <- sum(residuals(forward_model)^2) #RSS
sigma2_full <- summary(full_model)$sigma^2 #phuong sai
n <- nrow(train_data)
p_forward <- length(coef(forward_model))
# Cp = RSS / sigma2_full - (n - 2p)
cp_forward <- rss_forward / sigma2_full - (n - 2 * p_forward)

cat("Forward selection model:\n")

## Forward selection model:

cat("Adjusted R-squared:", round(adj_r2, 4), "\n")

## Adjusted R-squared: 0.4973

cat("Mallows' Cp:", round(cp_forward, 4), "\n")

## Mallows' Cp: 5.1116

cat("AIC:", round(AIC(forward_model), 2), "\n")

## AIC: 3835.51

cat("BIC:", round(BIC(forward_model), 2), "\n")

## BIC: 3870.31

```

Thuật toán Forward Selection bắt đầu từ mô hình chỉ gồm hệ số chặn và lần lượt bổ sung các biến làm giảm giá trị AIC nhiều nhất ở mỗi bước. Kết quả cho thấy các biến được lựa chọn theo thứ tự là `ltg`, `bmi`, `map`, `tc`, `sex`, `ldl` và `glu`. Sau khi thêm biến `glu`, việc bổ sung các biến còn lại không làm giảm AIC nên thuật toán dừng lại.

Mô hình cuối cùng đạt Adjusted ($R^2 = 0.4973$), cho thấy mô hình giải thích được khoảng 49.73% biến thiên của biến phản hồi sau khi đã điều chỉnh theo số lượng biến. Giá trị này khá gần với mô hình đầy đủ nhưng sử dụng ít biến hơn, giúp mô hình gọn và dễ diễn giải hơn.

Giá trị AIC được hiển thị trong quá trình thực hiện hàm `step()` có thể khác với giá trị AIC tính từ hàm `AIC()`. Do cách xử lý hằng số trong công thức tính AIC, vì hằng số cố định nên không ảnh hưởng đến việc lựa chọn mô hình.

Table 2: Kết quả qua từng bước của Forward Selection

Step	Formula	Adj_R2	AIC	BIC	Cp
1	target ~ ltg	0.3213	3935.563	3947.162	120.9207
2	target ~ ltg + bmi	0.4353	3871.644	3887.110	42.8747
3	target ~ ltg + bmi + map	0.4644	3853.958	3873.290	23.7272
4	target ~ ltg + bmi + map + tc	0.4745	3848.199	3871.397	17.7104
5	target ~ ltg + bmi + map + tc + sex	0.4841	3842.725	3869.790	12.1537
6	target ~ ltg + bmi + map + tc + sex + ldl	0.4951	3836.103	3867.035	5.6325
7	target ~ ltg + bmi + map + tc + sex + ldl + glu	0.4973	3835.511	3870.309	5.1116
8	target ~ ltg + bmi + map + tc + sex + ldl + glu	0.4973	3835.511	3870.309	5.1116
9	target ~ ltg + bmi + map + tc + sex + ldl + glu	0.4973	3835.511	3870.309	5.1116
10	target ~ ltg + bmi + map + tc + sex + ldl + glu	0.4973	3835.511	3870.309	5.1116

Bảng trên trình bày các mô hình thu được ở từng bước của thuật toán Forward Selection cùng với các chỉ tiêu đánh giá gồm Adjusted (R^2), AIC, BIC và Mallows' (C_p). Các bước 8 - 10 cho kết quả trùng lặp với bước 7 do thuật toán không còn tìm được biến nào giúp cải thiện tiêu chuẩn lựa chọn, vì vậy mô hình giữ nguyên từ bước 7 trở đi.

4.1.4 Phân tích ưu và nhược điểm

4.1.4.1 Ưu điểm

- Hiệu suất tính toán cao: So với phương pháp tìm kiếm tất cả các tập con, Forward Selection giảm thiểu đáng kể chi phí xử lý dữ liệu, giúp tối ưu hóa thời gian xử lý khi số lượng biến lớn.

4.1.4.2 Nhược điểm

- Bẫy “tối ưu cục bộ”: Forward Selection ở mỗi bước chỉ chọn biến mang lại cải thiện tốt nhất tại thời điểm đó. Phương pháp này không có cơ chế xem xét lại các biến đã được chọn. Vì vậy, một biến sau khi được đưa vào mô hình sẽ tiếp tục được giữ lại, ngay cả khi ở các bước sau nó trở nên kém cần thiết hoặc trùng lặp thông tin với các biến mới.
- Bỏ sót các tương tác ẩn: Ở giai đoạn đầu, thuật toán thường đánh giá từng biến một cách riêng lẻ. Do đó, nó có thể bỏ qua những cặp biến hoặc nhóm biến có khả năng giải thích tốt khi được xét cùng nhau, nhưng lại thể hiện tác động yếu nếu xét riêng từng biến.

4.2 Backward Elimination (Loại trừ lùi)

4.2.1 Nguyên lý hoạt động:

Bắt đầu với một mô hình chứa đầy đủ tất cả các biến độc lập (predictors), sau đó loại bỏ biến có giá trị p -value cao nhất và lớn hơn mức ý nghĩa α_{crit} (hoặc α_{remove}). Tiếp theo, mô hình được tái ước lượng (refit) và tiếp tục loại bỏ biến ít có ý nghĩa thống kê nhất còn lại, với điều kiện giá trị p -value của nó vẫn lớn hơn α_{crit} . Như vậy, tất cả các biến “không có ý nghĩa thống kê” cũng sẽ bị loại bỏ và quy trình lựa chọn sẽ hoàn tất (Faraway 2015).

4.2.2 Thuật toán:

4.2.2.1 Bắt đầu

- Xuất phát với mô hình đầy đủ (Full Model). Lúc này mô hình lấy tất cả các biến độc lập cùng một lúc.
- Trạng thái mô hình:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

- Tập hợp biến trong mô hình (S_{in}): Chứa tất cả các biến $\{X_1, X_2, \dots, X_p\}$.
- Tập hợp biến đã bị loại (S_{out}): Rỗng ($\emptyset$).

4.2.2.2 Quy trình đi từng bước

• Bước 1: Đánh giá tập thể

- Chạy mô hình hồi quy với toàn bộ các biến đang có mặt trong tập S_{in} .
- Rà soát chỉ số đóng góp của từng biến số trong mối tương quan với các biến còn lại (thường dựa vào p-value của kiểm định t).
- Tìm ra biến có đóng góp thấp nhất (theo giả thuyết đặt ra ban đầu), gọi là X_{worst} .

• Bước 2: Ra quyết định

- Nếu chỉ số của X_{worst} vi phạm ngưỡng an toàn ($p\text{-value} > \alpha_{crit}$), thì thuật toán xoá bỏ X_{worst} ra khỏi mô hình.
- Cập nhật trạng thái: Loại trừ X_{worst} từ tập S_{in} ra tập S_{out} .
- Trạng thái mô hình lúc này: Rút bớt đi một biến độc lập.

• Bước 3: Tái cấu trúc vòng lặp

- Xây dựng lại một mô hình hồi quy mới với các biến còn lại trong tập S_{in} . Việc phân phối dữ liệu trong mô hình thay đổi, dẫn đến các biến sẽ có p-value mới. Thuật toán lại lặp lại Bước 1 để tìm biến tiếp theo có đóng góp thấp nhất trong mô hình và tiếp tục loại bỏ nếu vi phạm giả thuyết.
- Điều kiện dừng: Nếu tại một bước rà soát, biến mang giá trị thống kê thấp nhất trong mô hình hiện tại vẫn thoả mãn giả thuyết ý nghĩa thống kê ($p\text{-value} \leq \alpha_{crit}$) thì thuật toán dừng lại và giữ nguyên mô hình tinh gọn này.

• Tổng số mô hình tối đa:


$$\text{Total}_{\text{Backward}} = 1 + p + (p-1) + (p-2) + \dots + 2 = 1 + \frac{(p+2)(p-1)}{2}$$

(Công thức này xấp xỉ bằng $\frac{p(p+1)}{2}$ tương tự như Forward Selection).

Đường đi của Backward đối với dataset diabetes như sau:

Quá trình loại biến theo Backward Elimination

Mô hình tối ưu đạt được tại bước 3



• Diễn giải đường đi của Backward Elimination

Biểu đồ trên trực quan hóa quá trình Backward Elimination theo tiêu chí giảm chỉ số AIC như sau:

1. Điểm khởi đầu (Step 0 - Full Model):

- **Trạng thái:** Thuật toán bắt đầu với một mô hình đầy đủ chứa toàn bộ 10 biến độc lập ban đầu của tập dữ liệu.
- **Giá trị AIC:** Tại bước 0 này, AIC ở mức cao nhất. Điều này cho thấy việc đưa quá nhiều biến vào mô hình (bao gồm cả những biến gây nhiễu hoặc có hiện tượng đa cộng tuyến) làm cho mô hình bị chồng chéo, dẫn đến việc phạt thông tin cao và làm giảm khả năng tổng quát hóa của mô hình.

2. Xu hướng dịch chuyển của đường đồ thị (Từ Step 1 đến Step 3):

- **Hướng đi:** Đường đồ thị có xu hướng giảm dần AIC từ trái qua phải.
- **Ý nghĩa:**
 - Tại mỗi bước, thuật toán sẽ thử nghiệm loại bỏ lần lượt từng biến và tính toán lại AIC. Biến nào mà sau khi loại bỏ giúp giảm chỉ số AIC nhiều nhất sẽ bị loại bỏ.
 - Ở Step 1, biến age bị loại bỏ đầu tiên, chứng tỏ trong một mô hình tổng thể, age đóng góp ít thông tin có ý nghĩa nhất đối với sự tiến triển của bệnh tiểu đường. Việc loại age giúp AIC giảm.

- Các bước tiếp theo, thuật toán tiếp tục thanh lọc mô hình bằng cách loại bỏ các biến hệ số hdl, tch,... Đường AIC đi xuống minh chứng rằng mô hình đang hoạt động hiệu quả hơn khi loại bỏ bớt “nhiều”.

3. Điểm dừng tối ưu của thuật toán:

- Thuật toán tự động dừng lại ở Step 3 (sau khi đã loại bỏ 3 biến và giữ lại 7 biến tối ưu trong mô hình).
- Lý do dừng lại là vì tại thời điểm này, nếu thuật toán cố chấp loại bỏ thêm bất kỳ biến nào trong số 7 biến còn lại (như glu, ldl, sex,...), giá trị AIC sẽ bị tăng ngược trở lại. Điều đó có nghĩa là 7 biến còn lại đều là những biến mang lượng thông tin cực kỳ quan trọng để giải thích biến phụ thuộc.

4.2.3 Áp dụng

```
backward_model <- step(
  full_model,
  direction = "backward",
  trace = TRUE
)
```

```
## Start:  AIC=2837.63
## target ~ age + sex + bmi + map + tc + ldl + hdl + tch + ltg +
##      glu
##
##           Df Sum of Sq      RSS      AIC
## - age      1         107 1027716 2835.7
## - hdl      1         149 1027757 2835.7
## - tch      1         230 1027838 2835.7
## - ldl      1        4670 1032278 2837.2
## <none>                1027608 2837.6
## - glu      1        6695 1034303 2837.9
## - tc       1        6864 1034472 2838.0
## - sex      1       41361 1068969 2849.6
## - ltg      1       45557 1073165 2850.9
## - map      1       70758 1098366 2859.1
## - bmi      1      120624 1148232 2874.8
##
## Step:  AIC=2835.66
## target ~ sex + bmi + map + tc + ldl + hdl + tch + ltg + glu
##
##           Df Sum of Sq      RSS      AIC
## - hdl      1         147 1027863 2833.7
## - tch      1         219 1027935 2833.7
## - ldl      1        4676 1032392 2835.3
## <none>                1027716 2835.7
## - tc       1       6821 1034537 2836.0
```

```
## - glu    1      7302 1035018 2836.2
## - sex    1      41351 1069067 2847.6
## - ltg    1      45658 1073373 2849.0
## - map    1      74642 1102357 2858.4
## - bmi    1     120584 1148300 2872.8
##
## Step:  AIC=2833.71
## target ~ sex + bmi + map + tc + ldl + tch + ltg + glu
##
##          Df Sum of Sq      RSS      AIC
## - tch     1          81 1027943 2831.7
## <none>          1027863 2833.7
## - glu     1       7377 1035240 2834.2
## - ldl     1       8733 1036596 2834.7
## - tc      1      23293 1051155 2839.6
## - sex     1      41445 1069307 2845.7
## - map     1      74582 1102444 2856.4
## - ltg     1      88506 1116368 2860.9
## - bmi     1     120988 1148851 2871.0
##
## Step:  AIC=2831.74
## target ~ sex + bmi + map + tc + ldl + ltg + glu
##
##          Df Sum of Sq      RSS      AIC
## <none>          1027943 2831.7
## - glu     1       7575 1035518 2832.3
## - ldl     1      23132 1051076 2837.6
## - sex     1      41647 1069590 2843.8
## - tc      1      41680 1069623 2843.8
## - map     1      74937 1102880 2854.6
## - bmi     1     120958 1148902 2869.0
## - ltg     1     193172 1221115 2890.5
```

```
summary_backward <- summary(backward_model)

adj_r2_backward <- summary_backward$adj.r.squared # R2 adj

# Mallows' Cp
rss_backward <- sum(residuals(backward_model)^2) # RSS
sigma2_full <- summary(full_model)$sigma^2 # phương sai từ full model
n <- nrow(train_data)
p_backward <- length(coef(backward_model)) # số tham số, bao gồm intercept

# Cp = RSS / sigma2_full - (n - 2p)
cp_backward <- rss_backward / sigma2_full - (n - 2 * p_backward)

cat("Backward selection model:\n")
```

```
## Backward selection model:
```

```
cat("Adjusted R-squared:", round(adj_r2_backward, 4), "\n")
```

```
## Adjusted R-squared: 0.4973
```

```
cat("Mallows' Cp:", round(cp_backward, 4), "\n")
```

```
## Mallows' Cp: 5.1116
```

```
cat("AIC:", round(AIC(backward_model), 2), "\n")
```

```
## AIC: 3835.51
```

```
cat("BIC:", round(BIC(backward_model), 2), "\n")
```

```
## BIC: 3870.31
```

Thuật toán Backward Elimination bắt đầu từ mô hình đầy đủ và lần lượt loại bỏ các biến age, hdl và tch do việc loại bỏ các biến này giúp giảm giá trị AIC. Mô hình cuối cùng gồm các biến sex, bmi, map, tc, ldl, ltg và glu, đạt Adjusted ($R^2 = 0.4973$). Kết quả này trùng với mô hình thu được từ Forward Selection, cho thấy tập biến được lựa chọn khá ổn định.

```
# BACKWARD SELECTION
```

```
full_model <- lm(target ~ ., data = train_data)
```

```
current_model <- full_model
```

```
backward_metrics <- data.frame()
```

```
previous_formula <- ""
```

```
n <- nrow(train_data)
```

```
sigma2_full <- summary(full_model)$sigma^2
```

```
step_num <- 0
```

```
repeat {
```

```
  step_num <- step_num + 1
```

```
  # chạy đúng 1 step
```

```

next_model <- step(
  current_model,
  direction = "backward",
  steps = 1,
  trace = FALSE
)

current_formula <- deparse(formula(next_model))

# nếu model không đổi thì stop
if(current_formula == previous_formula) {
  break
}

previous_formula <- current_formula


summary_fit <- summary(next_model)

rss <- sum(residuals(next_model)^2)

p <- length(coef(next_model))

adj_r2 <- summary_fit$adj.r.squared

aic <- AIC(next_model)

bic <- BIC(next_model)

# Mallows Cp
cp <- rss / sigma2_full - (n - 2 * p)

backward_metrics <- rbind(
  backward_metrics,
  data.frame(
    Step = step_num,
    Formula = current_formula,
    Num_predictors = p - 1,
    Adj_R2 = round(adj_r2, 4),
    AIC = round(aic, 2),
    BIC = round(bic, 2),
    Cp = round(cp, 2)
  )
)

```

```

current_model <- next_model
}

knitr::kable(
  backward_metrics,
  digits = 4,
  caption = "Kết quả qua từng bước của Backward Elimination"
)

```

Table 3: Kết quả qua từng bước của Backward Elimination

Step	Formula	Num_predictors	Adj_R2	AIC	BIC	Cp
1	target ~ sex + bmi + map + tc + ldl + hdl + tch + ltg + glu	9	0.4945	3839.43	3881.96	9.04
2	target ~ sex + bmi + map + tc + ldl + tch + ltg + glu	8	0.4959	3837.48	3876.15	7.08
3	target ~ sex + bmi + map + tc + ldl + ltg + glu	7	0.4973	3835.51	3870.31	5.11

Kết quả cho thấy việc loại bỏ các biến age, hdl và tch giúp cải thiện chất lượng mô hình. Mô hình cuối cùng gồm 7 biến có Adjusted (R^2) lớn nhất, đồng thời AIC, BIC và Mallows' (C_p) nhỏ nhất.

4.2.4 Phân tích ưu và nhược điểm

4.2.4.1 Ưu điểm:

- Xem xét toàn bộ biến ngay từ đầu: Bắt đầu với mô hình đầy đủ, bao gồm tất cả các biến dự báo. Từ đó, cho phép đánh giá vai trò của từng biến trong mối quan hệ đa biến tổng thể, hạn chế khả năng bỏ sót những biến chỉ có ý nghĩa khi được xem xét đồng thời cùng các biến khác.

4.2.4.2 Nhược điểm:

- Không thể thực thi với dữ liệu cao chiều: Do Backward Elimination cần xây dựng mô hình đầy đủ ngay từ đầu, phương pháp này hoàn toàn không thể thực thi khi số biến dự báo lớn hơn số lượng quan sát ($p > n$). Khi đó, ma trận hiệp biến không khả nghịch, hệ thống không đủ bậc tự do để ước lượng các hệ số bằng phương pháp OLS.

4.3 Stepwise Selection (Lựa chọn từng bước)

Là sự kết hợp giữa hai phương pháp loại trừ lùi và chọn tiến. Phương pháp này giải quyết được trường hợp khi các biến được thêm vào hoặc loại bỏ ở giai đoạn đầu của quy trình, nhưng lại muốn thay đổi quyết định (thêm hoặc bớt các biến) đối với chúng ở các giai đoạn sau. Tại mỗi bước, một biến có thể được thêm vào hoặc bị loại bỏ, và mô hình liên tục được tái đánh giá toàn diện (Faraway 2015).

4.3.1 Nguyên lý hoạt động:

1. Thuật toán bắt đầu tương tự như *Forward Selection* bằng cách thêm từng biến một vào mô hình rỗng.
2. Tuy nhiên, tại mỗi bước sau khi một biến mới được thêm vào, thuật toán sẽ thực hiện ngay một lượt rà soát lùi (*Backward elimination*) đối với toàn bộ các biến đã hiện diện trước đó trong mô hình.
3. Nếu một biến đã được đưa vào từ các bước trước nhưng nay trở nên dư thừa hay không còn ý nghĩa thống kê do sự xuất hiện phối hợp của các biến mới, nó sẽ lập tức bị loại bỏ.
4. Quy trình dừng lại khi không có biến nào ngoài mô hình đủ điều kiện để thêm vào và đồng thời không có biến nào trong mô hình thỏa mãn điều kiện loại ra.

4.3.2 Thuật toán:

4.3.2.1 Bắt đầu:

- Mô hình rỗng (Null Model).
- Trạng thái mô hình:

$$Y = \beta_0$$

- Hai ngưỡng kiểm định thiết lập bắt buộc: Ngưỡng đầu vào (α_{enter}) và Ngưỡng loại trừ (α_{remove}).
- Điều kiện ràng buộc:

$$\alpha_{\text{enter}} < \alpha_{\text{remove}}$$

4.3.2.2 Quy trình đi từng bước (Chu kỳ lặp kép):

- **Pha 1: Thêm biến (Forward Step):**

- Thuật toán quét qua tập biến ngoài mô hình S_{out} , tìm biến X_{best} tốt nhất.
- Nếu X_{best} thỏa mãn điều kiện đầu vào ($p\text{-value} \leq \alpha_{\text{enter}}$), thì thêm nó vào tập S_{in} .

- **Pha 2: Kiểm tra nội bộ (Backward Step)**

- Ngay sau khi biến mới được thêm vào mô hình, cấu trúc hiệp biến thay đổi. Việc tính toán dừng lại, ước lượng lại mô hình với tập S_{in} mới và quét một lượt các tiêu chuẩn của tất cả các biến đang có mặt ở trong mô hình.
- Do hiện tượng đa cộng tuyến, sự xuất hiện của biến mới có thể làm tăng $p\text{-value}$ của một biến cũ. Nếu phát hiện có bất kỳ biến cũ nào bị vượt ngưỡng đầu ra ($p\text{-value} > \alpha_{\text{remove}}$), thuật toán lập tức đẩy biến cũ đó trở lại tập S_{out} .

- **Điều kiện dừng:**

- Thuật toán lặp đi lặp lại chu kỳ kép này liên tục và dừng lại khi chạm đến điểm cân bằng động: nếu ở ngoài không còn bất kỳ biến nào đủ tốt để thỏa mãn tiêu chuẩn bước vào ($p\text{-value} \leq \alpha_{\text{enter}}$), đồng thời ở bên trong không còn bất cứ biến nào vi phạm tiêu chuẩn đầu ra ($p\text{-value} > \alpha_{\text{remove}}$).


- **Tổng số mô hình tối đa mà Stepwise phải tính toán xấp xỉ:**

$$\text{Total}_{\text{Stepwise}} \approx p^2$$

Biểu đồ đường đi của stepwise như sau:

Quá trình lựa chọn biến theo Stepwise Selection & Đánh giá các ứng viên

Đường liền: Được chọn | Hình xanh nhạt: Các ứng viên thay thế tại mỗi bước
Mô hình tối ưu đạt được tại bước 7



Diễn giải mô hình Stepwise Regression

1. Trạng thái khởi tạo và Xu hướng tổng quan

- **Bước khởi đầu (Step 0):** Thuật toán xuất phát từ mô hình rỗng chỉ chứa hệ số chặn (Intercept). Tại đây, giá trị chỉ số AIC đạt mức tối đa.
- **Xu hướng dịch chuyển:** Giảm dần AIC từ trái qua phải.

2. Cơ chế đánh giá tập hợp ứng viên

- **Sàng lọc biến nạp (Step 1 đến Step 6):** Tại Step 1, các phương án thử nghiệm (Thử thêm biến (+)) phân tán ở vùng AIC cao. Thuật toán thực hiện bước đi + ltg nhờ vị trí điểm này nằm ở đáy thấp nhất của tập hợp ứng viên, chứng tỏ biến ltg mang lại lượng thông tin biên lớn nhất tại thời điểm xét duyệt. Cơ chế này lặp lại tương tự để nạp lần lượt + bmi, + map, + tc, + sex và ldl.
- **Điểm cực trị tối ưu toàn cục (Step 7):** Hành động + glu đưa giá trị AIC chạm mức tối thiểu trên toàn bộ không gian trạng thái. Đây chính là cấu hình mô hình đạt trạng thái cân bằng lý tưởng giữa sức mạnh giải thích và độ tinh gọn.
- **Hiện tượng quá khớp và bão hòa thông tin (Step 8 đến Step 10):** Kể từ Step 8 trở đi, khi ép thuật toán chạy hết số bước định sẵn (Full Steps), dải ứng viên (bao gồm cả Thử thêm biến và Thử loại biến) co cụm sát nhau và đường lộ trình chính thức bắt đầu đi ngang. Hiện tượng dao động luân phiên ở các bước cuối mà không làm giảm thêm AIC là minh chứng trực quan cho thấy mô hình đã rơi vào trạng thái quá khớp (Overfitting), việc tích hợp thêm biến không còn mang lại hiệu ứng cải thiện ý nghĩa.

Nhận xét: Khác với tính chất một chiều của Forward hay Backward Selection, cơ chế rà soát hai chiều của Stepwise Selection cho phép đánh giá đồng và liên tục toàn bộ tập hợp ứng viên tại từng thời điểm. Phương pháp này xử lý hiệu quả hiện tượng đa cộng tuyến và sự trùng lặp thông tin, đảm bảo mô hình cuối cùng đạt cấu trúc tối ưu nhất.

4.3.3 Áp dụng

```
# Giả sử đã có null_model và full_model
stepwise_model <- step(
  null_model,
  scope = list(lower = null_model, upper = full_model),
  direction = "both",
  trace = TRUE
)
```

```
## Start:  AIC=3067.61
## target ~ 1
##
##      Df Sum of Sq    RSS    AIC
## + ltg   1    674365 1411972 2931.8
## + bmi   1    650520 1435817 2937.7
## + map   1    424474 1661862 2989.3
## + glu   1    345678 1740659 3005.7
## + tch   1    329032 1757304 3009.0
## + hdl   1    281569 1804767 3018.4
## + tc    1    102448 1983888 3051.8
## + age   1     89777 1996560 3054.1
## + ldl   1     61536 2024800 3059.0
## <none>                2086336 3067.6
## + sex   1        151 2086185 3069.6
##
## Step:  AIC=2931.79
## target ~ ltg
##
##      Df Sum of Sq    RSS    AIC
## + bmi   1    240514 1171457 2867.9
## + map   1    127791 1284180 2900.3
## + hdl   1     51536 1360436 2920.7
## + glu   1     50871 1361101 2920.8
## + tc    1     16769 1395202 2929.6
## + sex   1      8172 1403799 2931.7
## <none>                1411972 2931.8
## + tch   1       7517 1404454 2931.9
## + age   1      4211 1407760 2932.7
## + ldl   1        856 1411116 2933.6
## - ltg   1    674365 2086336 3067.6
```

```

##
## Step: AIC=2867.87
## target ~ ltg + bmi
##
##      Df Sum of Sq    RSS    AIC
## + map  1      63542 1107915 2850.2
## + tc   1      20838 1150620 2863.5
## + hdl  1      16228 1155230 2864.9
## + glu  1      14655 1156802 2865.4
## + sex  1       8940 1162517 2867.2
## + ldl  1       8035 1163422 2867.4
## <none>          1171457 2867.9
## + age  1       2166 1169292 2869.2
## + tch  1         58 1171399 2869.9
## - bmi  1     240514 1411972 2931.8
## - ltg  1     264359 1435817 2937.7
##
## Step: AIC=2850.19
## target ~ ltg + bmi + map
##
##      Df Sum of Sq    RSS    AIC
## + tc   1      24088 1083827 2844.4
## + sex  1      22544 1085371 2844.9
## + hdl  1      16546 1091369 2846.9
## + ldl  1       9988 1097927 2849.0
## <none>          1107915 2850.2
## + glu  1       4895 1103020 2850.6
## + age  1        423 1107493 2852.1
## + tch  1        162 1107754 2852.1
## - map  1      63542 1171457 2867.9
## - bmi  1     176265 1284180 2900.3
## - ltg  1     180256 1288172 2901.4
##
## Step: AIC=2844.43
## target ~ ltg + bmi + map + tc
##
##      Df Sum of Sq    RSS    AIC
## + sex  1      22705 1061122 2838.9
## + ldl  1       9435 1074392 2843.3
## + hdl  1       6642 1077186 2844.3
## + glu  1       6504 1077323 2844.3
## <none>          1083827 2844.4
## + tch  1       4917 1078910 2844.8
## + age  1         66 1083761 2846.4
## - tc   1      24088 1107915 2850.2
## - map  1      66792 1150620 2863.5
## - bmi  1     178770 1262597 2896.3
## - ltg  1     201567 1285394 2902.6

```

```

##
## Step: AIC=2838.95
## target ~ ltg + bmi + map + tc + sex
##
##      Df Sum of Sq    RSS    AIC
## + ldl   1     25604 1035518 2832.3
## + hdl   1     21103 1040018 2833.9
## + tch   1     17332 1043790 2835.1
## + glu   1     10046 1051076 2837.6
## <none>                1061122 2838.9
## + age   1         673 1060449 2840.7
## - sex   1     22705 1083827 2844.4
## - tc    1     24249 1085371 2844.9
## - map   1     80705 1141827 2862.8
## - bmi   1    173433 1234554 2890.4
## - ltg   1    207171 1268293 2899.9
##
## Step: AIC=2832.33
## target ~ ltg + bmi + map + tc + sex + ldl
##
##      Df Sum of Sq    RSS    AIC
## + glu   1       7575 1027943 2831.7
## <none>                1035518 2832.3
## + age   1        693 1034825 2834.1
## + tch   1        278 1035240 2834.2
## + hdl   1          0 1035518 2834.3
## - ldl   1     25604 1061122 2838.9
## - sex   1     38874 1074392 2843.3
## - tc    1     43592 1079110 2844.9
## - map   1     86982 1122500 2858.8
## - bmi   1    133519 1169037 2873.1
## - ltg   1    229162 1264680 2900.9
##
## Step: AIC=2831.74
## target ~ ltg + bmi + map + tc + sex + ldl + glu
##
##      Df Sum of Sq    RSS    AIC
## <none>                1027943 2831.7
## - glu   1       7575 1035518 2832.3
## + age   1         98 1027845 2833.7
## + tch   1         81 1027863 2833.7
## + hdl   1          9 1027935 2833.7
## - ldl   1     23132 1051076 2837.6
## - sex   1     41647 1069590 2843.8
## - tc    1     41680 1069623 2843.8
## - map   1     74937 1102880 2854.6
## - bmi   1    120958 1148902 2869.0
## - ltg   1    193172 1221115 2890.5

```

```
summary(stepwise_model)
```

```
##
## Call:
## lm(formula = target ~ ltg + bmi + map + tc + sex + ldl + glu,
##     data = train_data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -153.693  -37.589   -1.241    36.487   146.940
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   153.426      2.909   52.744 < 2e-16 ***
## ltg           751.347     93.313    8.052 1.34e-14 ***
## bmi           476.133     74.728    6.372 5.99e-10 ***
## map           356.067     71.000    5.015 8.50e-07 ***
## tc           -674.370    180.305   -3.740 0.000215 ***
## sex          -252.620     67.570   -3.739 0.000217 ***
## ldl           460.130    165.138    2.786 0.005625 **
## glu           114.258     71.661    1.594 0.111755
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 54.59 on 345 degrees of freedom
## Multiple R-squared:  0.5073, Adjusted R-squared:  0.4973
## F-statistic: 50.75 on 7 and 345 DF,  p-value: < 2.2e-16
```

```
# Tính Adj R-squared
```

```
summary_stepwise <- summary(stepwise_model)
adj_r2_stepwise <- summary_stepwise$adj.r.squared
```

```
# Mallows' Cp
```

```
rss_stepwise <- sum(residuals(stepwise_model)^2)
sigma2_full <- summary(full_model)$sigma^2
n <- nrow(train_data)
p_stepwise <- length(coef(stepwise_model))
cp_stepwise <- rss_stepwise / sigma2_full - (n - 2 * p_stepwise)
```

```
#
cat("\nStepwise selection model:\n")
```

```
##
## Stepwise selection model:
```

```
cat("Adjusted R-squared:", round(adj_r2_stepwise, 4), "\n")
```

```
## Adjusted R-squared: 0.4973
```

```
cat("Mallows' Cp:", round(cp_stepwise, 4), "\n")
```

```
## Mallows' Cp: 5.1116
```

```
cat("AIC:", round(AIC(stepwise_model), 2), "\n")
```

```
## AIC: 3835.51
```

```
cat("BIC:", round(BIC(stepwise_model), 2), "\n")
```

```
## BIC: 3870.31
```

Stepwise Selection lựa chọn mô hình gồm các biến ltg, bmi, map, tc, sex, ldl và glu. Mô hình thu được có Adjusted ($R^2 = 0.4973$), đồng thời đạt các giá trị AIC, BIC và Mallows' (C_p) tương tự Forward Selection và Backward Elimination. Điều này cho thấy kết quả lựa chọn biến nhất quán giữa các phương pháp.

```
# STEPWISE SELECTION
```

```
null_model <- lm(target ~ 1, data = train_data)
```

```
full_model <- lm(target ~ ., data = train_data)
```

```
# Model hiện tại
```

```
current_model <- null_model
```

```
stepwise_metrics <- data.frame()
```

```
previous_formula <- ""
```

```
n <- nrow(train_data)
```

```
sigma2_full <- summary(full_model)$sigma^2
```

```
step_num <- 0
```

```
repeat {
```

```
  step_num <- step_num + 1
```

```

next_model <- step(
  current_model,
  scope = list(
    lower = null_model,
    upper = full_model
  ),
  direction = "both",
  steps = 1,
  trace = FALSE
)

current_formula <- deparse(formula(next_model))

if(current_formula == previous_formula) {
  break
}

previous_formula <- current_formula


summary_fit <- summary(next_model)

rss <- sum(residuals(next_model)^2)

p <- length(coef(next_model))

adj_r2 <- summary_fit$adj.r.squared

aic <- AIC(next_model)

bic <- BIC(next_model)

# Mallows Cp
cp <- rss / sigma2_full - (n - 2 * p)


stepwise_metrics <- rbind(
  stepwise_metrics,
  data.frame(
    Step = step_num,
    Formula = current_formula,
    Num_predictors = p - 1,
    Adj_R2 = round(adj_r2, 4),
    AIC = round(aic, 2),
    BIC = round(bic, 2),
    Cp = round(cp, 2)
  )
)

```



```

    )
  )

  # update model
  current_model <- next_model
}

#KQ

knitr::kable(
  stepwise_metrics,
  digits = 4,
  caption = "Kết quả qua từng bước của stepwise"
)
```

Table 4: Kết quả qua từng bước của stepwise

Step	Formula	Num_predictors	Adj_R2	AIC	BIC	Cp
1	target ~ ltg	1	0.3213	3935.56	3947.16	120.92
2	target ~ ltg + bmi	2	0.4353	3871.64	3887.11	42.87
3	target ~ ltg + bmi + map	3	0.4644	3853.96	3873.29	23.73
4	target ~ ltg + bmi + map + tc	4	0.4745	3848.20	3871.40	17.71
5	target ~ ltg + bmi + map + tc + sex	5	0.4841	3842.72	3869.79	12.15
6	target ~ ltg + bmi + map + tc + sex + ldl	6	0.4951	3836.10	3867.03	5.63
7	target ~ ltg + bmi + map + tc + sex + ldl + glu	7	0.4973	3835.51	3870.31	5.11

Kết quả cho thấy việc bổ sung các biến giúp cải thiện chất lượng mô hình, thể hiện qua Adjusted (R^2) tăng dần và các chỉ tiêu AIC, BIC, Mallows' (C_p) giảm dần. Mô hình tại bước 7 cho kết quả tốt nhất và được chọn làm mô hình cuối cùng.

4.3.4 Phân tích ưu và nhược điểm

4.3.4.1 Ưu điểm:

- Linh hoạt: Stepwise cho phép mô hình sửa sai liên tục bằng cơ chế “thêm mới - rà soát cũ”, kiểm soát hiện tượng đa cộng tuyến cục bộ.
- Hạn chế trùng lặp thông tin: Mô hình được tinh lọc liên tục, đảm bảo tập hợp biến giữ lại là tinh gọn và phối hợp tối ưu.

4.3.4.2 Nhược điểm:

- Phụ thuộc vào cách đặt ngưỡng: Thuật toán phụ thuộc và việc thiết lập cặp giá trị ($\alpha_{\text{enter}}, \alpha_{\text{remove}}$). Nếu thiết lập không hợp lý, vòng lặp có thể rơi vào trạng thái lặp vô hạn (một biến bị thêm vào rồi lại bị loại ra liên tục).

- Vấn đề kiểm định nhiều lần (Multiple testing): Việc thực hiện liên tiếp các chuỗi kiểm định giả thuyết thống kê (t hoặc F) trên cùng một tập dữ liệu làm gia tăng sai lầm loại I tích lũy. Các chỉ số p -value ở mô hình cuối cùng có xu hướng bị quá nhỏ so với thực tế.

4.4 So sánh tổng hợp các phương pháp lựa chọn biến

Tiêu chí	Forward Selection	Backward Selection	Stepwise Selection
Điểm bắt đầu	Mô hình rỗng, chỉ chứa hệ số chặn β_0 .	Mô hình đầy đủ, chứa toàn bộ p biến ban đầu.	Mô hình rỗng, chỉ chứa hệ số chặn β_0 .
Cơ chế chính	Thêm dần: Tại mỗi bước, nạp biến độc lập có đóng góp tốt nhất vào mô hình.	Loại trừ dần: Tại mỗi bước, gạch tên biến độc lập ít hữu ích nhất ra khỏi mô hình.	Thêm/Bớt linh hoạt: Thực hiện pha tiến để thêm biến mới, rồi kiểm tra lùi để loại biến cũ bị lu mờ.
Điều kiện dừng (Stopping Criteria)	Khi không có biến nào ở ngoài thỏa mãn ngưỡng đầu vào	Khi tất cả các biến giữ lại đều đạt điều kiện giữ lại.	Khi đạt trạng thái cân bằng động: Bên ngoài không còn biến đủ tốt để vào ($\leq \alpha_{\text{enter}}$), bên trong không còn biến để bị loại trừ ($> \alpha_{\text{remove}}$).
Tổng số mô hình tối đa	$\frac{p(p+1)}{2}$	$1 + \frac{(p+2)(p-1)}{2}$	$\approx p^2$
Hạn chế đối với dữ liệu cao chiều	Chạy được từ bước 1, nhưng bị chặn khi số biến được chọn chạm mốc số lượng quan sát (n).	Không thể thực thi nếu $p > n$, vì mô hình đầy đủ ban đầu không thể ước lượng được bằng OLS.	Chạy được từ bước 1, nhưng cũng sẽ bị chặn hoặc gặp lỗi đa cộng tuyến nghiêm trọng nếu không có hiệu chỉnh.
Ưu điểm cốt lõi	- Tốc độ tính toán nhanh - Phù hợp hơn khi số lượng biến ban đầu lớn.	- Nhìn được bức tranh toàn cảnh ngay từ đầu - Giữ được các biến có tính tương tác, bổ trợ cho nhau	- Có cơ chế tự sửa sai liên tục và kiểm soát hiện tượng đa cộng tuyến tốt.
Nhược điểm cốt lõi	Biến đã lọt vào mô hình thì không bao giờ bị loại ra, dễ giữ lại thông tin trùng lặp.	Biến đã bị gạch tên thì không bao giờ có cơ hội quay lại mô hình.	Tốn chi phí tính toán hơn so với hai phương pháp đơn lẻ (do phải quét hai chiều).

Trong cả 3 phương pháp lựa chọn biến, BIC luôn đưa ra subset biến thấp hơn, với Stepwise selection, BIC chọn 6 biến, trong khi AIC và C_p chọn 7 biến. Nên trong phần kiểm định chéo, chúng ta sẽ tập trung vào mô hình 7 biến được AIC và C_p lựa chọn làm mô hình cuối cùng để đánh giá hiệu năng trên tập test (vì BIC có xu hướng chọn mô hình quá đơn giản và ưu tiên tính chính xác, trong khi AIC mạnh hơn về hiệu quả dự báo, có thể bỏ sót các biến quan trọng).

5 Lựa chọn mô hình và Bootstrap

5.1 Lựa chọn mô hình

Table 5: So sánh các mô hình được lựa chọn bởi các phương pháp khác nhau

Method	Predictors	Num_predictors	AIC	BIC	Adj_R2
Full model	age, sex, bmi, map, tc, ldl, hdl, tch, ltg, glu	10	3841.396	3887.794	0.4931
Best subset theo BIC	sex, bmi, map, hdl, ltg	5	3838.638	3865.703	0.4900
Best subset theo Adjusted R2	sex, bmi, map, tc, ldl, ltg, glu	7	3835.511	3870.309	0.4973
Best subset theo Cp	sex, bmi, map, tc, ldl, ltg, glu	7	3835.511	3870.309	0.4973
Forward AIC	ltg, bmi, map, tc, sex, ldl, glu	7	3835.511	3870.309	0.4973
Backward AIC	sex, bmi, map, tc, ldl, ltg, glu	7	3835.511	3870.309	0.4973
Stepwise AIC	ltg, bmi, map, tc, sex, ldl, glu	7	3835.511	3870.309	0.4973

```
final_model <- stepwise_model
```

```
summary(final_model)
```

```
##
## Call:
## lm(formula = target ~ ltg + bmi + map + tc + sex + ldl + glu,
##     data = train_data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -153.693  -37.589   -1.241    36.487   146.940
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   153.426     2.909   52.744 < 2e-16 ***
## ltg           751.347     93.313    8.052 1.34e-14 ***
## bmi           476.133     74.728    6.372 5.99e-10 ***
## map           356.067     71.000    5.015 8.50e-07 ***
## tc           -674.370    180.305   -3.740 0.000215 ***
## sex          -252.620     67.570   -3.739 0.000217 ***
## ldl           460.130    165.138    2.786 0.005625 **
## glu           114.258     71.661    1.594 0.111755
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 54.59 on 345 degrees of freedom
## Multiple R-squared:  0.5073, Adjusted R-squared:  0.4973
```

```
## F-statistic: 50.75 on 7 and 345 DF, p-value: < 2.2e-16
```

```
# So sánh mô hình rút gọn và mô hình đầy đủ bằng partial F-test
```

```
# Mô hình đầy đủ
```

```
full_model <- lm(target ~ ., data = train_data)
```

```
# Mô hình rút gọn
```

```
reduced_model <- final_model
```

```
nested_test <- anova(reduced_model, full_model)
```

```
nested_test
```

```
## Analysis of Variance Table
```

```
##
```

```
## Model 1: target ~ ltg + bmi + map + tc + sex + ldl + glu
```

```
## Model 2: target ~ age + sex + bmi + map + tc + ldl + hdl + tch + ltg +
```

```
## glu
```

```
## Res.Df RSS Df Sum of Sq F Pr(>F)
```

```
## 1 345 1027943
```

```
## 2 342 1027608 3 335.21 0.0372 0.9904
```

Kiểm định F được sử dụng để so sánh mô hình rút gọn và mô hình đầy đủ:

$$H_0 : \beta_{age} = \beta_{hdl} = \beta_{tch} = 0$$

$$H_1 : \text{Có ít nhất một hệ số trong } \beta_{age}, \beta_{hdl}, \beta_{tch} \text{ khác } 0$$

Trong đó, H_0 cho rằng ba biến bị loại khỏi mô hình rút gọn gồm age, hdl và tch không đóng góp đáng kể vào khả năng giải thích của mô hình. Ngược lại, H_1 cho rằng ít nhất một trong ba biến này có đóng góp đáng kể, nên mô hình đầy đủ phù hợp hơn mô hình rút gọn.

Kết quả kiểm định cho $p\text{-value} = 0.9904 > 0.05$, do đó không bác bỏ H_0 . Điều này cho thấy việc thêm các biến age, hdl và tch vào mô hình không làm cải thiện mô hình một cách có ý nghĩa thống kê. Vì vậy, mô hình rút gọn được ưu tiên do đơn giản hơn nhưng không kém mô hình đầy đủ về mặt thống kê.

5.2 Bootstrap

Để đánh giá độ ổn định của mô hình cuối cùng, sử dụng phương pháp Bootstrap với 1000 lần lấy mẫu ngẫu nhiên có hoàn lại từ tập train. Bootstrap Standard Error được sử dụng để đánh giá mức độ biến động của các hệ số hồi quy dưới những mẫu dữ liệu khác nhau (James et al. 2023).

```
coef(final_model)
```

```
## (Intercept)          ltg          bmi          map          tc          sex
##    153.4261    751.3469    476.1331    356.0667   -674.3702   -252.6204
##          ldl          glu
##    460.1299    114.2584
```

```
boot.fn <- function(data, index){

  boot_data <- data[index, ]

  fit <- lm(
    formula(final_model),
    data = boot_data
  )

  coef(fit)
}
```

```
set.seed(7)
```

```
boot_result <- boot(
  data = train_data,
  statistic = boot.fn,
  R = 1000
)
```

```
boot_result
```

```
##
## ORDINARY NONPARAMETRIC BOOTSTRAP
##
##
## Call:
## boot(data = train_data, statistic = boot.fn, R = 1000)
##
##
## Bootstrap Statistics :
##      original      bias    std. error
## t1*   153.4261 -0.140775557    3.002238
## t2*   751.3469  2.428353531   85.173380
## t3*   476.1331  0.416558637   75.534588
## t4*   356.0667 -1.577814502   73.484587
## t5*  -674.3702  3.330403590  156.964156
## t6*  -252.6204  4.026766305   66.207892
## t7*   460.1299 -3.855003958  150.398966
## t8*   114.2584  0.004882492   69.242729
```

Kết quả Bootstrap với 1000 lần lấy mẫu cho thấy các hệ số hồi quy có độ lệch (bias) rất nhỏ so với giá trị ước lượng ban đầu, cho thấy sai lệch do lấy mẫu lại là không đáng kể. Đồng thời, các sai số chuẩn bootstrap

ở mức tương đối ổn định đối với hầu hết các biến trong mô hình. Nhìn chung, kết quả Bootstrap cho thấy mô hình cuối cùng có độ tin cậy và tính ổn định tương đối tốt trước sự thay đổi của dữ liệu.

```
#Bootstrap Standard Error vs Standard Error
summary(final_model)$coef
```

##	Estimate	Std. Error	t value	Pr(> t)
## (Intercept)	153.4261	2.908881	52.744004	3.340869e-167
## ltg	751.3469	93.313365	8.051868	1.336210e-14
## bmi	476.1331	74.728393	6.371516	5.989301e-10
## map	356.0667	71.000069	5.015019	8.500388e-07
## tc	-674.3702	180.305485	-3.740154	2.152788e-04
## sex	-252.6204	67.569958	-3.738650	2.165196e-04
## ldl	460.1299	165.137737	2.786340	5.625460e-03
## glu	114.2584	71.660763	1.594434	1.117545e-01

Kết quả hồi quy cho thấy hầu hết các biến được lựa chọn đều có ý nghĩa thống kê ở mức 5%, với p-value nhỏ hơn 0. Các biến ltg, bmi, map, tc, sex và ldl đều có ảnh hưởng có ý nghĩa đến biến mục tiêu. Riêng biến glu có p-value bằng 0.1118, lớn hơn mức ý nghĩa 5%, nên chưa có đủ bằng chứng thống kê để khẳng định hệ số của biến này khác 0.

Tuy nhiên, biến glu vẫn được giữ lại trong mô hình cuối cùng do được lựa chọn bởi các phương pháp Forward Selection, Backward Elimination và Stepwise Selection dựa trên tiêu chuẩn AIC. Điều này cho thấy mặc dù glu không có ý nghĩa thống kê mạnh khi xét riêng lẻ, biến này vẫn góp phần cải thiện khả năng dự báo và chất lượng tổng thể của mô hình.

6 Kiểm chứng chéo (Cross - Validation)

Khi huấn luyện mô hình, cần phân biệt giữa **Training Error** và **Test Error**. **Training Error** là sai số được tính trên chính tập dữ liệu dùng để huấn luyện mô hình, trong khi **Test Error** là sai số khi mô hình dự đoán trên dữ liệu mới chưa từng được sử dụng trong quá trình huấn luyện. Trong thực tế, **Test Error** thường quan trọng hơn vì nó phản ánh khả năng tổng quát hóa của mô hình.

Training Error thường có xu hướng thấp hơn thực tế, do mô hình đã được xây dựng dựa trên chính dữ liệu đó. Do đó, **Training Error** thường không phản ánh chính xác khả năng dự đoán của mô hình trên dữ liệu mới. **Cross-Validation** là một phương pháp dùng để ước lượng **Test Error** bằng cách chia dữ liệu thành nhiều phần, lần lượt dùng một phần để kiểm tra và các phần còn lại để huấn luyện. Cách làm này giúp đánh giá mô hình ổn định hơn khi chưa có một tập kiểm thử độc lập (James et al. 2023).

6.1 Tập kiểm chứng độc lập (The Validation Set Approach)

6.1.1 Cơ chế

- Chia ngẫu nhiên dữ liệu gốc thành hai phần độc lập: **Tập huấn luyện** (Training Set) chiếm phần lớn dùng để xây dựng mô hình và **Tập kiểm chứng** (Validation set / test set) là phần còn lại không cho mô hình biết trước, dùng để tính lỗi sau khi mô hình đã học xong (James et al. 2023).

- Mô hình học trên tập Train và đo lường sai số (MSE/RMSE) trên tập Validation.

Bản chất toán học: Tập dữ liệu kiểm chứng hoàn toàn không tham gia vào bất kỳ một bước nào trong quá trình tối ưu hóa các hệ số β hay trọng số của mô hình. Do đó, điểm số lỗi thu được trên tập này phản ánh năng lực của mô hình khi gặp dữ liệu lạ. Phương pháp **chỉ yêu cầu khớp (fit) mô hình đúng 1 lần duy nhất** trên tập huấn luyện.

```
pred_train <- predict(final_model, newdata = train_data)

train_MSE <- mean((train_data$target - pred_train)^2)
train_RMSE <- sqrt(train_MSE)
train_MAE <- mean(abs(train_data$target - pred_train))

train_R2 <- 1 - sum((train_data$target - pred_train)^2) /
  sum((train_data$target - mean(train_data$target))^2)

train_results <- data.frame(
  Method = "Train error",
  MSE = train_MSE,
  RMSE = train_RMSE,
  MAE = train_MAE,
  R2 = train_R2
)

train_results
```

```
##           Method      MSE      RMSE      MAE      R2
## 1 Train error 2912.021 53.96314 43.30618 0.5072974
```

```
pred_test <- predict(final_model, newdata = test_data)

test_MSE <- mean((test_data$target - pred_test)^2)
test_RMSE <- sqrt(test_MSE)
test_MAE <- mean(abs(test_data$target - pred_test))

test_R2 <- 1 - sum((test_data$target - pred_test)^2) /
  sum((test_data$target - mean(test_data$target))^2)

test_results <- data.frame(
  Method = "Test error",
  MSE = test_MSE,
  RMSE = test_RMSE,
  MAE = test_MAE,
  R2 = test_R2
)

test_results
```

##	Method	MSE	RMSE	MAE	R2
## 1	Test error	2761.934	52.55411	43.75674	0.5400705

Mô hình đạt RMSE = 53.96 trên tập train và RMSE = 52.55 trên tập test. Đồng thời, giá trị (R^2) trên tập train và test lần lượt là 0.5073 và 0.5401. Kết quả cho thấy mô hình có khả năng dự báo trên tập mới.

6.1.2 Phân tích ưu và nhược điểm:

6.1.2.1 Ưu điểm Tối ưu hóa hiệu năng và chi phí tính toán khi chỉ yêu cầu khớp (fit) mô hình một lần duy nhất.

6.1.2.2 Nhược điểm

- Ước lượng sai số có phương sai cao (High Variance): Kết quả đánh giá mô hình (MSE hoặc RMSE), phụ thuộc khá nhiều vào cách chia dữ liệu ban đầu. Nếu tập validation/test chứa nhiều quan sát nhiễu hoặc không đại diện tốt cho toàn bộ dữ liệu, sai số ước lượng có thể cao hơn thực tế. Ngược lại, nếu tập validation/test tương đối “dễ dự đoán”, sai số có thể bị đánh giá thấp. Vì vậy, kết quả có thể thay đổi đáng kể giữa các lần chia dữ liệu khác nhau.
- Có thể đánh giá sai số kiểm thử cao hơn thực tế (High Bias): Mô hình chỉ được huấn luyện trên một phần dữ liệu, thay vì toàn bộ dữ liệu hiện có. Do kích thước tập huấn luyện nhỏ hơn, mô hình có thể học được ít thông tin hơn, làm cho sai số trên tập validation có xu hướng cao hơn so với trường hợp mô hình được huấn luyện trên toàn bộ dữ liệu.
- Không tận dụng hết dữ liệu: Một phần dữ liệu được tách ra để làm tập validation nên không được dùng trong quá trình huấn luyện mô hình. Điều này có thể làm giảm lượng thông tin mà mô hình học được, đặc biệt khi kích thước mẫu ban đầu còn hạn chế.

6.2 Kiểm chứng chéo loại một (LOOCV)

Để hạn chế nhược điểm lãng phí dữ liệu của phương pháp tập kiểm chứng, **LOOCV** sử dụng gần như toàn bộ dữ liệu để huấn luyện mô hình ở mỗi lần lặp.

6.2.1 Cơ chế

Giả sử tập dữ liệu có n quan sát. Ở mỗi lần lặp, LOOCV giữ lại một quan sát làm tập kiểm chứng và dùng $n - 1$ quan sát còn lại để huấn luyện mô hình.

Cụ thể, ở lần lặp thứ i , quan sát thứ i được dùng làm tập kiểm chứng, còn toàn bộ các quan sát còn lại được dùng để huấn luyện mô hình. Sau đó, sai số dự đoán trên quan sát thứ i được tính và ký hiệu là MSE_i . Quy trình này được lặp lại cho đến khi mỗi quan sát trong tập dữ liệu đều đã một lần được dùng làm tập kiểm chứng.

Sai số LOOCV được tính bằng trung bình sai số qua n lần lặp:

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i$$


```
glm_final <- glm(final_formula, data = train_data)
```

```
loocv_result <- cv.glm(train_data, glm_final)
```

```
LOOCV_MSE <- loocv_result$delta[1]
```

```
LOOCV_RMSE <- sqrt(LOOCV_MSE)
```

```
cat("LOOCV_MSE :", round(LOOCV_MSE, 4), "\n")
```

```
## LOOCV_MSE : 3044.52
```

```
cat("LOOCV_RMSE:", round(LOOCV_RMSE, 4), "\n")
```

```
## LOOCV_RMSE: 55.1772
```

6.2.2 Phân tích ưu và nhược điểm:

6.2.2.1 Ưu điểm Không bị thiên vị (bias thấp) vì mô hình được học gần như toàn bộ dữ liệu ($n - 1$ dòng). Kết quả LOOCV là duy nhất và ổn định, không bị yếu tố chia mẫu ngẫu nhiên chi phối.

6.2.2.2 Nhược điểm Nhược điểm lớn nhất của LOOCV là chi phí tính toán, phải khớp (fit) mô hình n lần trên n tập dữ liệu có quy mô $n - 1$.

Lưu ý:

Đối với hồi quy tuyến tính ước lượng bằng phương pháp bình phương tối thiểu thông thường (OLS), sai số LOOCV có thể được tính mà không cần khớp lại mô hình n lần. Thay vào đó, ta có thể dùng công thức:

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$$

Trong đó, $y_i - \hat{y}_i$ là **phần dư (residual)** khi mô hình được khớp trên toàn bộ dữ liệu, còn h_i là **giá trị đòn bẩy (leverage)** của quan sát thứ i , được lấy từ đường chéo của **ma trận hat (hat matrix)** (James et al. 2023).

Giải thích công thức:

- Khi mô hình được khớp trên toàn bộ dữ liệu, quan sát thứ i cũng tham gia vào quá trình ước lượng hệ số. Vì vậy, phần dư $y_i - \hat{y}_i$ thường nhỏ hơn so với trường hợp quan sát đó bị loại ra khỏi tập huấn luyện như trong LOOCV.
- Hệ số h_i cho biết mức độ ảnh hưởng của quan sát thứ i lên giá trị dự báo của chính nó. Nếu h_i lớn, quan sát đó có ảnh hưởng mạnh hơn đến đường hồi quy. Khi đó, mẫu số $(1 - h_i)$ nhỏ hơn, làm cho phần dư hiệu chỉnh $\frac{y_i - \hat{y}_i}{1 - h_i}$ lớn hơn.
- Nói cách khác, công thức này điều chỉnh phần dư thông thường bằng cách tính đến mức độ ảnh hưởng của từng quan sát. Nhờ đó, ta có thể ước lượng sai số LOOCV cho mô hình OLS chỉ từ một lần khớp mô hình trên toàn bộ dữ liệu.

6.3 Kiểm chứng chéo K phần

Đây là phương pháp trung hòa hai phương pháp nêu trên và được sử dụng rộng rãi nhất trong thực tế hiện nay.

6.3.1 Cơ chế

Chia ngẫu nhiên dữ liệu thành K phần bằng nhau (gọi là các folds).

Lần 1: Giữ fold 1 làm Validation, dùng các fold còn lại để Train $\rightarrow$ Tính MSE_1

Lần 2: Giữ fold 2 làm Validation, dùng các fold còn lại để Train $\rightarrow$ Tính $MSE_2 \dots$

Lặp lại K lần sao cho mỗi fold đều được làm Validation đúng 1 lần.

Công thức tính lỗi tổng hợp:

$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i$$

(Lưu ý: Nếu cấu hình hệ số $K = n$, mỗi fold sẽ thu hẹp lại chỉ chứa đúng 1 quan sát duy nhất. Quy trình xoay vòng K lần lúc này đồng nhất tuyệt đối với cơ chế hoạt động của LOOCV) (James et al. 2023).

```
set.seed(347)

kfold_result <- cv.glm(train_data, glm_final, K = 5)

KFold_MSE <- kfold_result$delta[1]
KFold_RMSE <- sqrt(KFold_MSE)

cat("KFold_MSE :", round(KFold_MSE, 4), "\n")
```

```
## KFold_MSE : 3042.676
```

```
cat("KFold_RMSE:", round(KFold_RMSE, 4), "\n")
```

```
## KFold_RMSE: 55.1605
```

6.3.2 Phân tích ưu và nhược điểm:

6.3.2.1 Ưu điểm

- Đánh giá khách quan, giảm thiểu Overfitting: Đảm bảo tất cả các quan sát trong tập dữ liệu đều được dùng để huấn luyện lẫn kiểm tra ít nhất một lần giúp ước lượng sai số kiểm thử một cách khách quan và chính xác hơn.
- Tận dụng tối đa dữ liệu: Hiệu quả khi kích thước mẫu (sample size) nhỏ. Việc chia thành K phần giúp mô hình luôn được huấn luyện trên một lượng lớn dữ liệu ($(K - 1)/K$ tổng số mẫu) ở mỗi lượt.
- Khắc phục được nhược điểm chi phí tính toán của LOOCV và bảo đảm sự khách quan, tối ưu dữ liệu hơn Validation Set.

6.3.2.2 Nhược điểm

- Phụ thuộc vào cách chọn số fold (K): Hiệu quả của K-Fold Cross-Validation phụ thuộc vào giá trị K được chọn. Nếu K quá nhỏ, chẳng hạn $K = 2$, mỗi mô hình chỉ được huấn luyện trên một phần tương đối nhỏ của dữ liệu, nên sai số ước lượng có thể bị thiên lệch cao. Ngược lại, nếu K quá lớn, thời gian tính toán sẽ tăng lên do mô hình phải được huấn luyện nhiều lần hơn.
- Không phù hợp với một số dạng dữ liệu đặc thù: K-Fold Cross-Validation thông thường giả định các quan sát độc lập và có cùng phân phối. Vì vậy, phương pháp này có thể không phù hợp với dữ liệu chuỗi thời gian, do việc chia ngẫu nhiên có thể làm mất trật tự thời gian của dữ liệu. Với dữ liệu mất cân bằng, các fold được chia ngẫu nhiên cũng có thể không giữ được tỷ lệ giữa các lớp, làm cho kết quả đánh giá mô hình kém ổn định.

7 Tài liệu tham khảo

1. Akaike, H. (1973). Information theory and an extension of the maximum likelihood principle. *Proc. 2nd Int. Symp. Information Theory*, 267–281.
Nguồn gốc lý thuyết về tiêu chuẩn thông tin AIC trong việc tối ưu hóa hàm tựa lỗi và lựa chọn mô hình.
2. Bingham, N. H., & Fry, J. M. (2010). *Regression: Linear Models in Statistics*. Springer Science & Business Media.
Cơ sở lý thuyết hệ thống về các mô hình tuyến tính trong thống kê dành cho bậc đại học.
3. Burnham, K. P., & Anderson, D. R. (2004). Multimodel inference: Understanding AIC and BIC in model selection. *Sociological Methods & Research*, 33(2), 261–304.
Phân tích chuyên sâu và so sánh bản chất triết học, ứng dụng của AIC và BIC trong suy luận đa mô hình.
4. Dalpiaz, D. (2021). *Applied Statistics with R*. Illinois Open Publishing Network.
Trích dẫn về các tiêu chuẩn chọn biến AIC, BIC và Adjusted R^2 tại Chương 16, Mục 16.1, trang 383-386
5. Faraway, J. J. (2015). *Linear Models with R*. 2nd ed. Chapman and Hall/CRC.
Trích dẫn về hệ quả của Stepwise selection và các tiêu chuẩn đánh giá mô hình hồi quy tại Chương 10.
6. Hurvich, C. M., & Tsai, C.-L. (1989). Regression and time series model selection in small samples. *Biometrika*, 76(2), 297–307.
Nghiên cứu về tiêu chuẩn lựa chọn mô hình hồi quy và chuỗi thời gian đối với các tập dữ liệu mẫu nhỏ.
7. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2023). *An Introduction to Statistical Learning: with Applications in R*. 2nd ed. Springer New York.
Tham chiếu chính về lý thuyết Cross-validation tại Chương 5, Bootstrap tại Mục 5.3.4 và Subset Selection tại Chương 6, trang 233–235. Tham chiếu các tiêu chuẩn chọn biến AIC, BIC, C_p , Adjusted R^2 tại Mục 6.3.4, trang 232–235.
8. Mallows, C. L. (1973). Some comments on C_p . *Technometrics*, 15(4), 661–675.
Ghi chú và phân tích nền tảng về tiêu chuẩn Mallows' C_p phục vụ chọn lọc biến trong mô hình hồi quy.
9. Rencher, A. C., & Schaalje, G. B. (2008). *Linear Models in Statistics*. 2nd ed. John Wiley & Sons.
Cơ sở toán học ma trận của phương pháp OLS, kiểm định giả thuyết tuyến tính tổng quát và phân bố bậc tự do hồi quy tại Chương 7 & 8.
10. Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464.
Cơ sở toán học và định nghĩa gốc của tiêu chuẩn thông tin Bayes - BIC dựa trên xấp xỉ tích phân Laplace.

11. Sheather, S. J. (2009). *A Modern Approach to Regression with R*. Springer Science & Business Media.
Dẫn chứng về tiêu chuẩn so sánh thông tin AIC, BIC, phân tích cấu trúc đa cộng tuyến và lựa chọn biến tại Chương 7, trang 227–233.
12. Weisberg, S. (2014). *Applied Linear Regression*. 4th ed. John Wiley & Sons.
Tham chiếu về các phương pháp đánh giá, kiểm định và so sánh mô hình tuyến tính ứng dụng tại Chương 10, trang 238–239.
13. Yang, Y. (2005). Can the strengths of AIC and BIC be shared? A conflict between model identification and regression estimation. *Biometrika*, 92(4), 937–950.
Phân tích xung đột toán học giữa mục tiêu nhận dạng mô hình chính xác của BIC và mục tiêu tối ưu hóa dự báo của AIC.